



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

**Evaluación de Modelos de Deep Learning para la Detección Temprana de Retinopatía
Diabética**

Trabajo de investigación para el curso de Trabajo de Tesis I

Arroyo Almonacid José Eduardo
Asesor: Marks Calderón

Lima, 27 de mayo de 2024

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissim enim sit amet. Facilisi etiam dignissim diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissim enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Palabras claves: uno, dos, tres, cuatro

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissima enim sit amet. Faciliis etiam dignissima diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissima enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Keywords: uno, dos, tres, cuatro

Para mi X, Y,X

Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissima enim sit amet. Faciliti etiam dignissima diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissima enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

Índice general

Índice de Figuras	9
Índice de Tablas	10
1. PLANTEAMIENTO DEL PROBLEMA	11
1.1. Descripción de la Realidad Problemática	11
1.1.1. Problema General	12
1.1.2. Problemas Específicos	12
1.2. Objetivos de la Investigación	13
1.2.1. Objetivo General	13
1.2.2. Objetivos Específicos	13
1.3. Justificación de la Investigación	14
1.3.1. Teórica	14
1.3.2. Práctica	14
1.3.3. Metodológica	14
1.4. Delimitación del Estudio	15
1.4.1. Espacial	15
1.4.2. Temporal	15
1.4.3. Conceptual	15
1.5. Hipótesis	16

1.5.1.	Hipótesis General	16
1.5.2.	Hipótesis Específicas	16
1.5.3.	Matriz de Consistencia	16
2.	MARCO TEÓRICO	17
2.1.	Antecedentes de la investigación	17
2.1.1.	Deep Convolutional Neural Networks for Detecting COVID-19 Using Medical Images: A Survey	17
2.1.2.	Heart Disease Detection Using Machine Learning and Deep Learning .	18
2.1.3.	Monitoring and Recognition of Heart Health using Heartbeat Classifi- cation with Deep Learning and IoT	19
2.1.4.	Advances in Deep Learning: From Diagnosis to Treatment	20
2.1.5.	A Study on Scope of Artificial Intelligence in Diagnostic Medicine . .	21
2.2.	Bases Teóricas	22
2.2.1.	Machine Learning	22
2.2.2.	Deep Learning	22
2.2.3.	Redes Neuronales Convolutivas (CNNs)	23
2.2.4.	Procesamiento de Imágenes Médicas	23
2.2.5.	Técnicas de Preprocesamiento de Datos	23
2.2.6.	Evaluación de Modelos de Machine Learning y Deep Learning	23
2.2.7.	Retinopatía Diabética	23
2.2.8.	Sistemas de Diagnóstico Asistido por Computadora (CAD)	24
2.2.9.	Transferencia de Aprendizaje	24
2.2.10.	Inteligencia Artificial en Medicina	24
2.3.	Marco Conceptual	24
2.3.1.	Inteligencia Artificial (IA)	24
2.3.2.	Machine Learning (Aprendizaje Automático)	24

2.3.3. Deep Learning (Aprendizaje Profundo)	25
2.3.4. Redes Neuronales Convolutivas (CNNs)	25
2.3.5. Transferencia de Aprendizaje	25
2.3.6. Retinopatía Diabética	25
2.3.7. Sistemas de Diagnóstico Asistido por Computadora (CAD)	25
2.3.8. Preprocesamiento de Datos	25
2.3.9. Métricas de Evaluación	26
2.3.10. Base de Datos APTOS y Messidor	26
3. METODOLOGÍA DE LA INVESTIGACIÓN	27
3.1. Diseño de la investigación	27
3.1.1. Diseño no experimental	27
3.1.2. Tipo explicativo	27
3.1.3. Enfoque cuantitativo	28
3.2. Población y muestra	28
3.3. Operacionalización de Variables	28
3.4. Instrumentos de medida	29
3.5. Técnicas de recolección de datos	29
3.6. Técnicas para el procesamiento y análisis de la información	30
3.7. Cronograma de actividades y presupuesto	30
4. DESARROLLO DEL EXPERIMENTO	31
4.1. X	31
4.2. Y	31
4.3. Z	32
5. ANÁLISIS Y DISCUSIÓN DE RESULTADOS	33

5.1. X	33
5.2. Y	33
5.3. Z	34
6. CONCLUSIONES Y RECOMENDACIONES	35
6.1. Conclusiones	35
6.2. Recomendaciones	35
Anexos	36
A. Anexo I: Matriz de Consistencia	37
B. Anexo II: Resumen de Papers investigados	39
BIBLIOGRAFÍA	41

Índice de Figuras

3.1. Prueba de Figura	28
---------------------------------	----

Índice de Tablas

3.1. An example table.	30
4.1. An example table.	31
5.1. An example table.	33
A.1. Matriz de consistencia. Fuente: Elaboración propia	38
B.1. Cuadro Resumen de Papers investigados. Fuente: Elaboración propia	40

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

La retinopatía diabética (RD) constituye una complicación severa derivada de la diabetes, siendo la principal causa de pérdida de visión en adultos trabajadores en naciones desarrolladas. Esta afección impacta profundamente en la vida de las personas, no solo reduciendo su calidad de vida por la disminución visual, sino también imponiendo retos económicos significativos para los sistemas de salud debido al elevado precio de los tratamientos.

Globalmente, más de 537 millones de adultos viven con diabetes, y se estima que este número ascenderá a más de 780 millones para el año 2045. Un análisis exhaustivo muestra que alrededor del 34.6 % de estas personas desarrollarán alguna forma de RD, y un 7 % experimentará variantes severas como la retinopatía diabética proliferativa.

La repercusión socioeconómica de la RD es vasta, incluyendo no solo los costes directos de los tratamientos sino también la reducción de la capacidad laboral de los afectados, lo que puede llevar a la pérdida de autonomía y al desarrollo de trastornos emocionales. Las opciones de tratamiento avanzadas, como las inyecciones intraoculares y las intervenciones quirúrgicas retinianas, suponen un lastre económico adicional tanto para los pacientes como para los sistemas sanitarios.

Acceso Desigual a la Atención Médica

Existen notables disparidades en el acceso a los servicios médicos que pueden influir significativamente en la detección y tratamiento oportunos de la RD. Estas variaciones son particularmente evidentes entre distintas regiones y estratos socioeconómicos, y requieren ser abordadas en las políticas de salud para garantizar un tratamiento equitativo.

Impacto Psicológico y Comunitario

El deterioro visual grave resultante de la RD afecta no solo a nivel individual, sino que también repercute en el entorno familiar y comunitario del paciente, exacerbando problemas psicosociales como el estrés y la depresión.

Costos Económicos a Nivel Macro y Micro

Además de los gastos médicos directos, la RD acarrea costos indirectos por la pérdida de productividad laboral. Analizar estos aspectos desde una perspectiva global y local ofrece un panorama más claro para diseñar intervenciones efectivas y contextualizadas.

Innovaciones Tecnológicas en Detección y Tratamiento

La revolución tecnológica en la salud ha introducido herramientas como la inteligencia artificial y la telemedicina, las cuales están cambiando la forma de diagnóstico y tratamiento de la RD. Estas innovaciones presentan nuevas oportunidades pero también desafíos, particularmente en términos de acceso equitativo.

Políticas Públicas y Estrategias de Prevención Es esencial evaluar críticamente las políticas y estrategias de salud pública vigentes, identificando áreas de mejora para fortalecer la prevención y el tratamiento de la RD, a través de campañas más efectivas y programas de detección mejorados.

Futuro y Sostenibilidad del Sistema de Salud

Ante el incremento esperado en la prevalencia de la diabetes, es imperativo que los sistemas de salud se preparen para manejar esta carga creciente de manera eficiente y sostenible.

1.1.1. Problema General

¿De qué manera la detección inadecuada contribuye a la incidencia de ceguera y deterioro visual severo en la población diabética específicamente a través de la retinopatía diabética?

1.1.2. Problemas Específicos

- ¿Hasta qué punto la precisión de los modelos de deep learning en la detección temprana de la retinopatía diabética afecta la tasa de diagnósticos correctos y oportunos en comparación con los métodos convencionales de cribado?
- ¿De qué forma la calidad y disponibilidad de los datos de entrenamiento impactan la

capacidad de los modelos de deep learning para predecir de manera efectiva la retinopatía diabética, y cuál es su influencia en la prevención de la ceguera en pacientes diabéticos?

- ¿Cómo incide la variabilidad intra e inter observador en la anotación de datos en la precisión de los modelos de deep learning para detectar la retinopatía diabética en diversas poblaciones?

1.2. Objetivos de la Investigación

1.2.1. Objetivo General

Evaluar la precisión, fiabilidad y aplicabilidad de los modelos de deep learning en la identificación temprana de la retinopatía diabética, para establecer una metodología que contribuya a una detección más efectiva de la enfermedad.

1.2.2. Objetivos Específicos

- Evaluar y comparar la precisión de modelos seleccionados de deep learning en la identificación de características tempranas de la retinopatía diabética, frente a la precisión de los métodos de cribado tradicionales, y determinar su impacto en la mejora de los diagnósticos oportunos.
- Investigar el efecto de la calidad y la disponibilidad de datos en la precisión de los modelos de deep learning y su capacidad para detectar la retinopatía diabética, y cómo esto podría contribuir a la prevención de la ceguera en la población diabética.
- Analizar el grado de variabilidad en la anotación de datos por diferentes observadores y su influencia en la eficacia de los modelos de deep learning, con el objetivo de identificar y proponer estrategias para mejorar la consistencia en la detección de la retinopatía diabética en poblaciones variadas.

1.3. Justificación de la Investigación

1.3.1. Teórica

Este estudio se centra en la aplicación de modelos de aprendizaje profundo para la detección temprana de la retinopatía diabética, un problema de salud prevalente entre los diabéticos en Perú. Investigaciones recientes indican que hasta un 15.1 % de los pacientes en programas específicos de diabetes presentan esta condición, con una mayoría sufriendo de formas no proliferativas. Este proyecto busca profundizar el entendimiento de cómo los avances en inteligencia artificial pueden mejorar significativamente la detección y el seguimiento precoz de esta afección. Al hacerlo, la investigación aportará valiosos conocimientos sobre las capacidades y restricciones de las tecnologías emergentes en la oftalmología, enriqueciendo la literatura académica tanto a nivel local como internacional.

1.3.2. Práctica

Desde un punto de vista práctico, este trabajo de investigación tiene el potencial de generar una mejora considerable en el método de pre-detección de la retinopatía diabética en Perú, donde comúnmente el diagnóstico ocurre en fases muy avanzadas. Implementar modelos de deep learning para la identificación temprana de la enfermedad podría facilitar intervenciones preventivas más efectivas, aliviar la carga económica sobre el sistema de salud y mejorar significativamente los resultados para los pacientes. Integrar esta tecnología en los sistemas públicos de salud mejoraría la accesibilidad y eficacia del diagnóstico de la RD, especialmente en zonas donde los recursos son escasos.

1.3.3. Metodológica

Metodológicamente, este estudio se distingue por su análisis exhaustivo y comparativo de diversos modelos de deep learning en un entorno clínico real. La metodología rigurosa que se aplicará no solo evaluará la precisión de estos modelos, sino que también explorará adaptaciones necesarias para maximizar su eficacia en el contexto específico de Perú. Esto proporcionará una base sólida para futuras investigaciones y aplicaciones de IA en el tratamiento de otras condiciones médicas, además de influir en el desarrollo de políticas de salud pública relacionadas con la implementación de nuevas tecnologías.

1.4. Delimitación del Estudio

1.4.1. Espacial

Este estudio se delimita al análisis de datos obtenidos de bases de datos internacionales reconocidas, específicamente el Messidor dataset y el APTOS 2019. Estas bases contienen imágenes de fondo de ojo de pacientes diabéticos, recolectadas bajo diversos estudios clínicos. La selección de estas bases de datos se debe a su amplio uso en la investigación académica y su relevancia para validar la precisión de modelos de deep learning en el contexto de la retinopatía diabética. La investigación no involucrará la recolección de nuevos datos clínicos ni se realizarán pruebas directas con pacientes en Perú o cualquier otra región, concentrándose exclusivamente en el análisis técnico y comparativo de los datos ya existentes.

1.4.2. Temporal

La investigación se llevará a cabo durante el año académico 2024, comenzando en enero y concluyendo en diciembre del mismo año. Este marco temporal ha sido seleccionado para alinear el estudio con el calendario académico y permitir un tiempo adecuado para la planificación, ejecución y análisis de la evaluación de los modelos. Durante este período, se realizará la selección de modelos, el procesamiento de datos, la ejecución de pruebas computacionales y la análisis de los resultados.

1.4.3. Conceptual

La investigación está enfocada en la evaluación técnica de modelos de deep learning específicos que han sido previamente desarrollados y aplicados en la detección de la retinopatía diabética. La delimitación conceptual abarca la validación de la efectividad de estos modelos en términos de precisión, sensibilidad, especificidad y otras métricas relevantes para el diagnóstico automatizado a través de imágenes. Se excluyen del estudio la creación de nuevos modelos de IA, cualquier intervención médica directa con pacientes, y la exploración de tratamientos para la retinopatía. Este enfoque permite una concentración rigurosa en la evaluación del rendimiento de tecnologías específicas en un contexto controlado y basado en datos, proporcionando una evaluación crítica de su utilidad práctica y limitaciones.

1.5. Hipótesis

1.5.1. Hipótesis General

La precisión de los modelos de deep learning preexistentes en la detección temprana de la retinopatía diabética es significativamente alta, lo que sugiere su viabilidad como herramientas eficientes para la identificación preliminar de esta condición en las poblaciones examinadas a través de las bases de datos Messidor y APTOS 2019.

1.5.2. Hipótesis Específicas

- Los modelos de deep learning seleccionados demostrarán una precisión significativamente superior en la detección de signos tempranos de retinopatía diabética en imágenes retinianas en comparación con los métodos de cribado estándar, lo que se traduce en una reducción de los diagnósticos tardíos de la enfermedad.
- La calidad y la disponibilidad de los datos utilizados para entrenar y probar los modelos de deep learning tendrán un impacto directo y positivo en la precisión de la detección de la retinopatía diabética, lo que potencialmente podría disminuir la incidencia de ceguera entre los pacientes diabéticos.
- La variabilidad en la anotación de datos entre diferentes observadores afectará significativamente el rendimiento de los modelos de deep learning, y la implementación de protocolos estandarizados de anotación mejorará la consistencia y exactitud en la detección de la retinopatía diabética a través de diversas poblaciones.

1.5.3. Matriz de Consistencia

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo [A.1](#)).

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis que abordan diversas técnicas y enfoques utilizados para afrontar problemas similares al de esta tesis.

2.1.1. Deep Convolutional Neural Networks for Detecting COVID-19 Using Medical Images: A Survey

2.1.1.1. Planteamiento del Problema y objetivo

El COVID-19, causado por el virus SARS-CoV-2, se propagó rápidamente desde diciembre de 2019, representando una grave amenaza para la salud pública. La detección temprana y precisa es crucial para un tratamiento efectivo. Los métodos tradicionales tienen limitaciones en sensibilidad y tiempo, por lo que se investiga el uso de deep learning aplicado a imágenes médicas para mejorar la precisión y velocidad de diagnóstico.

2.1.1.2. Técnicas empleadas por los autores

Deep Learning en Medicina: Uso de redes neuronales convolutivas (CNN) para analizar imágenes médicas. Redes Neuronales Convolutivas (CNN): Uso de arquitecturas como VGG, ResNet y DenseNet. Transferencia de Aprendizaje: Redes preentrenadas en grandes bases de datos para mejorar la clasificación específica de COVID-19.

2.1.1.3. Metodología empleada por lo s autores

Modelos y Datasets Utilizados: Evaluación de CNNs (VGG16, DenseNet, ResNet) aplicadas a datasets como COVIDx. Evaluación de Modelos: Uso de métricas como precisión, sensibilidad, especificidad y AUC. Técnicas de Preprocesamiento: Normalización y aumento de datos para mejorar la calidad y variabilidad de las imágenes.

2.1.1.4. Resultados obtenidos

Avances en la Detección Automatizada: Los modelos de deep learning pueden igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos más rápidos. Impacto Clínico: La implementación de estos sistemas automatizados puede mejorar la detección temprana y reducir la carga de trabajo manual. Futuras Direcciones: Integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala.

2.1.2. Heart Disease Detection Using Machine Learning and Deep Learning

2.1.2.1. Planteamiento del Problema y objetivo

Las enfermedades del corazón se han convertido en una de las principales causas de muerte en todo el mundo, con aproximadamente 17.9 millones de muertes registradas anualmente. Detectar la presencia de enfermedades del corazón de manera temprana es crucial para monitorear y tratar a los pacientes a tiempo y así salvar vidas. Esta investigación tiene como objetivo utilizar técnicas de aprendizaje automático y profundo para detectar enfermedades cardíacas, mejorando la precisión y la eficacia del diagnóstico.

2.1.2.2. Técnicas empleadas por los autores

Deep Learning y Machine Learning en Medicina: Uso de redes neuronales y modelos de aprendizaje automático para analizar datos médicos. Redes Neuronales Convolutivas (CNN) y Modelos de Aprendizaje Automático: Se emplean modelos como SVM, Logistic Regression, Decision Tree, FFNN y LSTM. Selección de Características: Métodos como la matriz de correlación y el puntaje de Fisher para eliminar características no relevantes.

2.1.2.3. Metodología empleada por los autores

Modelos y Datasets Utilizados: Evaluación de modelos como Logistic Regression, SVM, Decision Tree, FFNN y LSTM aplicados a un conjunto de datos con 1026 registros. Evaluación de Modelos: Uso de técnicas de validación cruzada y métricas como precisión, sensibilidad, especificidad y AUC. Técnicas de Preprocesamiento: Métodos de normalización y selección de características para mejorar la calidad de los datos.

2.1.2.4. Resultados obtenidos

Avances en la Detección Automatizada: Los modelos de aprendizaje profundo y automático pueden igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos más rápidos y precisos. Impacto Clínico: La implementación de estos sistemas automatizados puede mejorar la detección temprana y reducir la carga de trabajo manual en entornos clínicos. Futuras Direcciones: Integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala y evaluación de su eficacia en diversos contextos clínicos.

2.1.3. Monitoring and Recognition of Heart Health using Heartbeat Classification with Deep Learning and IoT

2.1.3.1. Planteamiento del Problema y objetivo

Las enfermedades cardiovasculares, como la arritmia y el infarto de miocardio, representan graves problemas de salud que pueden ser mortales si no se detectan y tratan a tiempo. La detección temprana y precisa es crucial para un tratamiento efectivo. El objetivo de este estudio es utilizar técnicas de aprendizaje profundo y el Internet de las cosas (IoT) para mejorar la detección y clasificación de latidos cardíacos, lo que permite identificar problemas de salud cardíaca de manera automática y precisa.

2.1.3.2. Técnicas empleadas por los autores

Deep Learning en Medicina: Uso de redes neuronales convolutivas (CNN) y técnicas de IoT para monitorear y analizar la salud cardíaca. Redes Neuronales Convolutivas (CNN): Implementación de arquitecturas de CNN para la clasificación de latidos cardíacos. Optimización de Algoritmos: Uso de algoritmos de optimización para mejorar la precisión y eficiencia de los modelos de clasificación.

2.1.3.3. Metodología empleada por los autores

Modelos y Datasets Utilizados: Evaluación de CNNs aplicadas a datasets como el MIT-BIH arrhythmia database. Evaluación de Modelos: Uso de métricas como precisión, sensibilidad, especificidad y AUC. Técnicas de Preprocesamiento: Segmentación y extracción de características de las señales ECG para mejorar la calidad y variabilidad de los datos.

2.1.3.4. Resultados obtenidos

Avances en la Detección Automatizada: Los modelos de deep learning, integrados con IoT, pueden igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos más rápidos y precisos. Impacto Clínico: La implementación de estos sistemas automatizados puede mejorar la detección temprana de enfermedades cardíacas y reducir la carga de trabajo manual en entornos clínicos. Futuras Direcciones: Integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala y evaluación de su eficacia en diversos contextos clínicos.

2.1.4. Advances in Deep Learning: From Diagnosis to Treatment

2.1.4.1. Planteamiento del Problema y objetivo

El aprendizaje profundo ha revolucionado el campo del diagnóstico y tratamiento médico, alcanzando niveles de precisión comparables a los de los profesionales médicos en diversas tareas diagnósticas. Este estudio investiga el uso de modelos de aprendizaje profundo para integrar diferentes formas de datos médicos y proporcionar sugerencias diagnósticas y de tratamiento precisas y en tiempo real. El objetivo es mejorar la colaboración entre médicos y máquinas para ofrecer una atención médica personalizada y eficiente.

2.1.4.2. Técnicas empleadas por los autores

Deep Learning en Medicina**: Utilización de redes neuronales convolutivas (CNN) y modelos de aprendizaje profundo para tareas de diagnóstico y tratamiento. Modelos de Fundamento Médico**: Empleo de modelos avanzados de deep learning que integran grandes conjuntos de datos y múltiples formas de información médica. Optimización de Algoritmos**: Uso de técnicas de optimización para mejorar la precisión y eficiencia de los modelos en diversas tareas médicas.

2.1.4.3. Metodología empleada por los autores

Modelos y Datasets Utilizados**: Evaluación de modelos como R-CNN, U-Net y GPT-4 aplicados a conjuntos de datos médicos variados. Evaluación de Modelos**: Uso de métricas como precisión, sensibilidad, especificidad y AUC para evaluar la efectividad de los modelos. Técnicas de Preprocesamiento**: Normalización y aumento de datos para mejorar la calidad y variabilidad de los datos.

2.1.4.4. Resultados obtenidos

Avances en la Detección Automatizada**: Los modelos de deep learning pueden igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos y sugerencias de tratamiento más rápidos y precisos. Impacto Clínico**: La implementación de estos sistemas automatizados puede mejorar la detección temprana de enfermedades y reducir la carga de trabajo manual en entornos clínicos. Futuras Direcciones**: Integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala y evaluación de su eficacia en diversos contextos clínicos.

2.1.5. A Study on Scope of Artificial Intelligence in Diagnostic Medicine

2.1.5.1. Planteamiento del Problema y objetivo

La inteligencia artificial (IA) ha demostrado un potencial significativo para mejorar el diagnóstico médico al analizar grandes volúmenes de datos de manera rápida y precisa. Este estudio analiza cómo las técnicas de IA, incluyendo el aprendizaje automático y profundo, pueden integrarse en la medicina diagnóstica para mejorar la precisión del diagnóstico y optimizar la atención al paciente. El objetivo es explorar el alcance y las aplicaciones de la IA en el diagnóstico médico para mejorar los resultados de los pacientes y reducir los costos de atención médica.

2.1.5.2. Técnicas empleadas por los autores

Inteligencia Artificial en Medicina: Uso de algoritmos de aprendizaje automático y profundo para analizar datos médicos. Reconocimiento de Imágenes: Empleo de IA para examinar imágenes médicas como rayos X, tomografías computarizadas (CT) y resonancias magnéticas (MRI). Procesamiento del Lenguaje Natural (NLP): Análisis de registros de salud electrónicos

(EHR) y patrones de lenguaje para identificar indicios de enfermedades.

2.1.5.3. Metodología empleada por los autores

Modelos y Datasets Utilizados: Evaluación de algoritmos de IA aplicados a conjuntos de datos médicos diversos. Evaluación de Modelos: Uso de métricas como precisión, sensibilidad, especificidad y AUC para evaluar la efectividad de los modelos. Técnicas de Preprocesamiento: Normalización y aumento de datos para mejorar la calidad y variabilidad de los datos médicos.

2.1.5.4. Resultados obtenidos

Avances en la Detección Automatizada: Los modelos de IA pueden igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos más rápidos y precisos. Impacto Clínico: La implementación de sistemas automatizados de IA puede mejorar la detección temprana de enfermedades y reducir la carga de trabajo manual en entornos clínicos. Futuras Direcciones: Integración de modelos de IA en sistemas de salud reales para pruebas clínicas a gran escala y evaluación de su eficacia en diversos contextos clínicos.

2.2. Bases Teóricas

2.2.1. Machine Learning

El machine learning es un subcampo que se enfoca en ejecutar procesos aprendiendo de datos, en lugar de seguir reglas preprogramadas. Es importante mencionar que existen también cinco tipos de problemas de aprendizaje que se pueden enfrentar: regresión, clasificación, simulación, optimización y clusterización. Por otro lado, el aprendizaje automático también posee una división por subcampos que se puede observar en la Figura 14.

2.2.2. Deep Learning

El deep learning es una evolución del aprendizaje automático que utiliza redes neuronales profundas para modelar patrones complejos en grandes conjuntos de datos. Las redes neuronales convolutivas (CNNs) son una arquitectura comúnmente utilizada en el análisis de

imágenes médicas. Técnicas como la transferencia de aprendizaje y la regularización son fundamentales para mejorar el rendimiento de los modelos.

2.2.3. Redes Neuronales Convolutivas (CNNs)

Las CNNs son una clase de redes neuronales diseñadas específicamente para procesar datos con una estructura de cuadrícula, como las imágenes. Están compuestas por capas convolucionales, capas de pooling y capas fully connected, que permiten extraer y combinar características de las imágenes.

2.2.4. Procesamiento de Imágenes Médicas

El procesamiento de imágenes médicas incluye técnicas de preprocesamiento como la normalización y el aumento de datos para mejorar la calidad de las imágenes. La segmentación de imágenes y la extracción de características son pasos cruciales para analizar las imágenes médicas de manera efectiva.

2.2.5. Técnicas de Preprocesamiento de Datos

La normalización y estandarización de datos son técnicas esenciales para preparar los datos antes de entrenar los modelos. El aumento de datos (data augmentation) ayuda a incrementar la variabilidad de los datos de entrenamiento, mejorando la robustez del modelo.

2.2.6. Evaluación de Modelos de Machine Learning y Deep Learning

La evaluación de los modelos se realiza mediante métricas como la precisión, sensibilidad, especificidad, AUC y F1-score. La validación cruzada y otras técnicas de validación son fundamentales para garantizar la generalización del modelo.

2.2.7. Retinopatía Diabética

La retinopatía diabética es una complicación de la diabetes que afecta los ojos. Existen diferentes tipos de retinopatía diabética, y su detección temprana es crucial para prevenir la pérdida de visión. Los métodos tradicionales de diagnóstico incluyen el examen de fondo de ojo y la angiografía fluoresceínica.

2.2.8. Sistemas de Diagnóstico Asistido por Computadora (CAD)

Los sistemas CAD utilizan algoritmos de IA para asistir a los médicos en el diagnóstico de enfermedades. En el campo de la oftalmología, los sistemas CAD han demostrado ser efectivos en la detección temprana de la retinopatía diabética.

2.2.9. Transferencia de Aprendizaje

La transferencia de aprendizaje permite utilizar modelos preentrenados en grandes conjuntos de datos y adaptarlos a tareas específicas mediante fine-tuning. Esto es particularmente útil en la medicina, donde los datos etiquetados son limitados.

2.2.10. Inteligencia Artificial en Medicina

La inteligencia artificial ha tenido un impacto significativo en el diagnóstico médico, permitiendo diagnósticos más rápidos y precisos. Los avances en IA han mejorado la atención médica y se espera que continúen transformando el campo de la salud en el futuro.

2.3. Marco Conceptual

2.3.1. Inteligencia Artificial (IA)

La inteligencia artificial es una rama de las ciencias computacionales que busca emular la inteligencia humana a través de algoritmos y máquinas, permitiendo realizar actividades de manera más eficiente que el ser humano.

2.3.2. Machine Learning (Aprendizaje Automático)

Machine learning es una subdisciplina de la inteligencia artificial que utiliza técnicas de ingeniería y estadística para desarrollar algoritmos que permiten a las máquinas aprender de datos y realizar predicciones o decisiones sin ser explícitamente programadas para cada tarea.

2.3.3. Deep Learning (Aprendizaje Profundo)

El deep learning es una rama del machine learning que utiliza redes neuronales artificiales con múltiples capas (redes profundas) para modelar patrones complejos en grandes volúmenes de datos.

2.3.4. Redes Neuronales Convolutivas (CNNs)

Las redes neuronales convolutivas son un tipo de red neuronal profunda que es especialmente eficaz para el procesamiento y análisis de imágenes debido a su capacidad para capturar características espaciales jerárquicas.

2.3.5. Transferencia de Aprendizaje

La transferencia de aprendizaje es una técnica en deep learning donde un modelo preentrenado en una gran base de datos se adapta (fine-tuning) para realizar tareas específicas con un conjunto de datos diferente, mejorando la eficiencia y precisión del modelo en nuevas tareas.

2.3.6. Retinopatía Diabética

La retinopatía diabética es una complicación de la diabetes que afecta los vasos sanguíneos de la retina, llevando a una disminución de la visión y, en casos severos, a la ceguera.

2.3.7. Sistemas de Diagnóstico Asistido por Computadora (CAD)

Los sistemas CAD son herramientas que utilizan algoritmos de inteligencia artificial para ayudar a los médicos en el diagnóstico de enfermedades, mejorando la precisión y rapidez de los diagnósticos.

2.3.8. Preprocesamiento de Datos

El preprocesamiento de datos incluye técnicas como la normalización, estandarización, y aumento de datos (data augmentation) para preparar los datos antes de entrenar los modelos de aprendizaje automático y profundo.

2.3.9. Métricas de Evaluación

Las métricas de evaluación son criterios utilizados para medir el rendimiento de los modelos de machine learning y deep learning. Incluyen precisión, sensibilidad, especificidad, AUC, y F1-score.

2.3.10. Base de Datos APTOS y Messidor

Estas bases de datos contienen imágenes de fondo de ojo etiquetadas con diferentes grados de retinopatía diabética, utilizadas para entrenar y evaluar modelos de deep learning en la detección de esta enfermedad.

Capítulo 3

METODOLOGÍA DE LA INVESTIGACIÓN

3.1. Diseño de la investigación

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra.

3.1.1. Diseño no experimental

El diseño es no experimental longitudinal, ya que las variables no serán manipuladas y serán analizadas tal como se encuentran. Es decir, tanto los datos textuales (noticias) y el precio del cobre serán analizados sin ningún cambio aplicando técnicas de procesamiento de lenguaje natural y algoritmos de aprendizaje automático con la finalidad de crear un modelo productivo robusto y facilitar la predicción del cobre. Asimismo, la recolección de datos que se realizará será en un determinado periodo de tiempo.

3.1.2. Tipo explicativo

El alcance de la presente investigación es explicativo debido a que se busca explicar el comportamiento volátil del precio del cobre en base a noticias de periódicos digitales y además predecirlo.

3.1.3. Enfoque cuantitativo

El enfoque esta investigación es cuantitativo dado que se empleará técnicas del procesamiento de lenguaje natural (NLP), las cuales conllevan a procesar los datos de tipo textual a numéricos (vectores de características) y con ello posteriormente usar técnicas estadísticas como la regresión lineal para la predicción del precio del cobre.

3.2. Población y muestra

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit. La Figura 3.1 y el Cuadro 3.1




Figura 3.1: Prueba de Figura

3.3. Operacionalización de Variables

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus

mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

3.4. Instrumentos de medida

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat

- muscle and fat cells remove glucose from the blood,
- cells breakdown glucose via glycolysis and the citrate cycle, storing its energy in the form of ATP,
- liver and muscle store glucose as glycogen as a short-term energy reserve,
- adipose tissue stores glucose as fat for long-term energy reserve, and
- cells use glucose for protein synthesis.

3.5. Técnicas de recolección de datos

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

L^AT_EX is great at typesetting mathematics. Let X_1, X_2, \dots, X_n be a sequence of independent and identically distributed random variables with

$$S_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_i^n X_i \quad (\text{Ecuación 3.1})$$

La Ecuación [Ecuación 3.1](#) denote their mean. Then as n approaches infinity, the random variables

$$\sqrt{n}(S_n - \mu)$$

converge in distribution to a normal $\mathcal{N}(0, \sigma^2)$.

3.6. Técnicas para el procesamiento y análisis de la información

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

You can make lists with automatic numbering ...

1. Like this,
2. and like this.

... or bullet points ...

- Like this,
- and like this.

3.7. Cronograma de actividades y presupuesto

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 3.1: An example table.

Capítulo 4

DESARROLLO DEL EXPERIMENTO

4.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

4.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 4.1: An example table.

4.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

El paper es citado y el otro paper .

Capítulo 5

ANÁLISIS Y DISCUSIÓN DE RESULTADOS

5.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

5.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

Tabla 5.1: An example table.

5.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Capítulo 6

CONCLUSIONES Y RECOMENDACIONES

6.1. Conclusiones

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

6.2. Recomendaciones

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Anexos

Anexos A

Anexo I: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
¿De qué manera la detección inadecuada contribuye a la incidencia de ceguera y deterioro visual severo en la población diabética específicamente a través de la retinopatía diabética?	Evaluar la precisión, fiabilidad y aplicabilidad de los modelos de deep learning en la identificación temprana de la retinopatía diabética, para establecer una metodología que contribuya a una detección más efectiva de la enfermedad.	La precisión de los modelos de deep learning preexistentes en la detección temprana de la retinopatía diabética es significativamente alta, lo que sugiere su viabilidad como herramientas eficientes para la identificación preliminar de esta condición en las poblaciones examinadas a través de las bases de datos Messidor y APTOS 2019.
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿Hasta qué punto la precisión de los modelos de deep learning en la detección temprana de la retinopatía diabética afecta la tasa de diagnósticos correctos y oportunos en comparación con los métodos convencionales de cribado?	Evaluar y comparar la precisión de modelos seleccionados de deep learning en la identificación de características tempranas de la retinopatía diabética, frente a la precisión de los métodos de cribado tradicionales, y determinar su impacto en la mejora de los diagnósticos oportunos.	Los modelos de deep learning seleccionados demostrarán una precisión significativamente superior en la detección de signos tempranos de retinopatía diabética en imágenes retinianas en comparación con los métodos de cribado estándar, lo que se traduce en una reducción de los diagnósticos tardíos de la enfermedad.
¿De qué forma la calidad y disponibilidad de los datos de entrenamiento impactan la capacidad de los modelos de deep learning para predecir de manera efectiva la retinopatía diabética, y cuál es su influencia en la prevención de la ceguera en pacientes diabéticos?	Investigar el efecto de la calidad y la disponibilidad de datos en la precisión de los modelos de deep learning y su capacidad para detectar la retinopatía diabética, y cómo esto podría contribuir a la prevención de la ceguera en la población diabética.	La calidad y la disponibilidad de los datos utilizados para entrenar y probar los modelos de deep learning tendrán un impacto directo y positivo en la precisión de la detección de la retinopatía diabética, lo que potencialmente podría disminuir la incidencia de ceguera entre los pacientes diabéticos.
¿Cómo incide la variabilidad intra e inter observador en la anotación de datos en la precisión de los modelos de deep learning para detectar la retinopatía diabética en diversas poblaciones?	Analizar el grado de variabilidad en la anotación de datos por diferentes observadores y su influencia en la eficacia de los modelos de deep learning, con el objetivo de identificar y proponer estrategias para mejorar la consistencia en la detección de la reti-	La variabilidad en la anotación de datos entre diferentes observadores afectará significativamente el rendimiento de los modelos de deep learning, y la implementación de protocolos estandarizados de anotación mejorará la consistencia y exactitud en la detección de la retinopatía

Anexos B

Anexo II: Resumen de Papers investigados

Tipo	N°	Título	Autor	Año	País	Fuente
Problema	1	Copper price estimation using bat algorithm	Dehghani Bogdanovic	2018	United Kingdom	Resources Policy
	2	Alternative techniques for forecasting mineral commodity prices	Cortez, Saydam, Coulton, Sammut	2018	Netherlands	International Journal of Mining Science and Technology
Propuesta	3	Prediction of the crude oil price thanks to natural language processing applied to newspapers	Trastour, Genin, Morlot	2016	USA	Standfort University ML repository
	4	Stock Price Prediction Using Deep Learning	Tipirisetty	2018	USA	Master's Theses San Jose State University
	5	Deep Learning for Stock Prediction Using Numerical and Textual Information	Akita, R., Yoshihara, A., Matsubara, T., Uehara, K.	2016	USA	2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)
Técnica	6	Stock Prices Prediction using the Title of Newspaper Articles with Korean Natural Language Processing	Yun, Sim, Seok	2019	Japan	2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC)
	7	A Method of Optimizing LDA Result Purity Based on Semantic Similarity	Jingrui, Z., Qinglin, W., Yu, L., Yuan, L.	2017	China	2017 32nd Youth Academic Annual Conference of Chinese Association of Automation (YAC)
	8	Qualitative Stock Market Predicting with Common Knowledge Based Nature Language Processing: A Unified View and Procedure	Rao, D., Deng, F., Jiang, Z., Zhao, G.	2015	USA	2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics
	9	Fuzzy Bag-of-Words Model for Document Representation	Zhao, R., Mao, K.	2018	USA	IEEE Transactions on Fuzzy Systems (Volume: 26 , Issue: 2 , April 2018)

Tabla B.1: Cuadro Resumen de Papers investigados. Fuente: Elaboración propia

BIBLIOGRAFÍA

- Akita, R., Yoshihara, A., Matsubara, T., & Uehara, K. Deep learning for stock prediction using numerical and textual information. En: *En 2016 IEEE/ACIS 15th International Conference on Computer and Information Science (ICIS)*. IEEE. 2016, 1-6.
- Cortez, C. T., Saydam, S., Coulton, J., & Sammut, C. (2018). Alternative techniques for forecasting mineral commodity prices. *International Journal of Mining Science and Technology*, 28(2), 309-322.
- Dehghani, H., & Bogdanovic, D. (2018). Copper price estimation using bat algorithm. *Resources Policy*, 55, 55-61.
- Gartner. (2019). Gartner IT Glossary. <https://www.gartner.com/it-glossary/>
- Gollapudi, S. (2016). *Practical machine learning*. Packt Publishing Ltd.
- Goyal, P., Pandey, S., & Jain, K. (2018). Deep learning for natural language processing. *Deep Learning for Natural Language Processing: Creating Neural Networks with Python [Berkeley, CA]: Apress*, 138-143.
- IBM. (2019). IBM AI glossary. <https://www.ibm.com/cloud/garage/architectures/cognitiveArchitecture/glossary>
- Jingrui, Z., Qinglin, W., Yu, L., & Yuan, L. A method of optimizing LDA result purity based on semantic similarity. En: *En 2017 32nd Youth Academic Annual Conference of Chinese Association of Automation (YAC)*. IEEE. 2017, 361-365.
- Kulkarni, A., & Shivananda, A. (2019). Exploring and Processing Text Data. En *Natural Language Processing Recipes* (pp. 37-65). Springer.
- Lagos, G. (2017). ¿Cómo lo han hecho los especialistas?: aciertos y desaciertos al proyectar el precio del cobre. <https://gyn.claseejecutiva.uc.cl/como-lo-han-hecho-los-especialistas-aciertos-y-desaciertos-al-proyectar-el-precio-del-cobre/#>
- Martínez, R., & Cohen, E. (2018). Manual formulación, evaluación y monitoreo de proyectos sociales. <https://dds.cepal.org/redesoc/publicacion?id=242>
- Ministerio de Energía y Minas (ESTAMIN). (2019). *Perú: país líder de los metales del futuro* (Boletín Estadístico Minero).

- Rao, D., Deng, F., Jiang, Z., & Zhao, G. Qualitative Stock Market Predicting with Common Knowledge Based Nature Language Processing: A Unified View and Procedure. En: En *2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics*. 2. IEEE. 2015, 381-384.
- Real Academia Española. (2014). Diccionario de la lengua española (Twenty-third). <https://dle.rae.es/?w=diccionario>
- Royal Society Working Group. (2017). *Machine learning: the power and promise of computers that learn by example* (inf. téc.). Technical report.
- Study Group International Copper. (2018). The World Copper Factbook 2018. www.icsg.org
- TensorFlow. (2019). Vector Representations of Words. <https://www.tensorflow.org/tutorials/representation/word2vec>
- Tipirisetty, A. (2018). *Stock Price Prediction using Deep Learning* [Tesis de maestría, San José State University] [Master's Projects]. <https://doi.org/https://doi.org/10.31979/etd.bzmm-36m7>
- Trastour, S., Genin, M., & Morlot, A. (2016). Prediction of the crude oil price thanks to natural language processing applied to newspapers. <http://cs229.stanford.edu/proj2016/report/>
- U.S. Geological Survey. (2019). Mineral commodity summaries 2019: U.S. Geological Survey. <https://doi.org/https://doi.org/10.3133/70202434>
- Yun, H., Sim, G., & Seok, J. Stock Prices Prediction using the Title of Newspaper Articles with Korean Natural Language Processing. En: En *2019 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC)*. IEEE. 2019, 019-021.
- Zhao, R., & Mao, K. (2017). Fuzzy bag-of-words model for document representation. *IEEE Transactions on Fuzzy Systems*, 26(2), 794-804.