



UNIVERSIDAD ESAN  
FACULTAD DE INGENIERÍA  
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

**Evaluación de Modelos de Deep Learning para la Detección Temprana de Retinopatía  
Diabética**

Trabajo de investigación para el curso de Trabajo de Tesis I

Arroyo Almonacid José Eduardo  
Asesor: Marks Calderón

Lima, 10 de junio de 2024

## Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissima enim sit amet. Facilisi etiam dignissima diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissima enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

**Palabras claves:** uno, dos, tres, cuatro

## Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissima enim sit amet. Faciliis etiam dignissima diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissima enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

**Keywords:** uno, dos, tres, cuatro

Para mi X, Y,X

## Agradecimientos

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ac odio tempor orci dapibus ultrices in iaculis nunc sed. Vivamus arcu felis bibendum ut tristique et egestas quis ipsum. Odio morbi quis commodo odio aenean sed adipiscing diam donec. Donec ultrices tincidunt arcu non sodales neque sodales ut. Fusce ut placerat orci nulla pellentesque dignissim enim sit amet. Facilisi etiam dignissim diam quis enim lobortis. Sit amet justo donec enim diam vulputate ut pharetra. Gravida in fermentum et sollicitudin ac orci phasellus egestas. Ultricies tristique nulla aliquet enim tortor at auctor. Nullam vehicula ipsum a arcu cursus vitae congue mauris. Convallis posuere morbi leo urna molestie at elementum eu facilisis. Elit at imperdiet dui accumsan sit amet nulla. Amet consectetur adipiscing elit pellentesque habitant morbi tristique senectus et. Mauris in aliquam sem fringilla ut morbi. Ultricies integer quis auctor elit sed vulputate mi sit. Nulla pellentesque dignissim enim sit amet venenatis urna cursus eget. Ac feugiat sed lectus vestibulum mattis ullamcorper. Eu augue ut lectus arcu bibendum. Rhoncus dolor purus non enim praesent elementum.

Nulla facilisi cras fermentum odio eu feugiat pretium. Massa massa ultricies mi quis hendrerit. Id leo in vitae turpis massa sed elementum. Quis vel eros donec ac odio tempor orci. Netus et malesuada fames ac turpis egestas integer eget aliquet. Velit ut tortor pretium viverra suspendisse potenti. Ut enim blandit volutpat maecenas. Nibh tellus molestie nunc non blandit. Mus mauris vitae ultricies leo integer malesuada nunc vel. Vel elit scelerisque mauris pellentesque pulvinar pellentesque habitant. Neque viverra justo nec ultrices dui sapien eget. Vitae aliquet nec ullamcorper sit. Dui id ornare arcu odio ut sem nulla pharetra diam. Et magnis dis parturient montes. Varius morbi enim nunc faucibus.

# Índice general

<b>Índice de Figuras</b>	<b>9</b>
<b>Índice de Tablas</b>	<b>10</b>
<b>1. PLANTEAMIENTO DEL PROBLEMA</b>	<b>11</b>
1.1. Descripción de la Realidad Problemática . . . . .	11
1.2. Problema General . . . . .	13
1.2.1. Problemas Específicos . . . . .	13
1.3. Objetivos de la Investigación . . . . .	13
1.3.1. Objetivo General . . . . .	13
1.3.2. Objetivos Específicos . . . . .	13
1.4. Justificación de la Investigación . . . . .	14
1.4.1. Teórica . . . . .	14
1.4.2. Práctica . . . . .	14
1.4.3. Metodológica . . . . .	15
1.5. Delimitación del Estudio . . . . .	15
1.5.1. Espacial . . . . .	15
1.5.2. Temporal . . . . .	16
1.5.3. Conceptual . . . . .	16
1.6. Hipótesis . . . . .	16

1.6.1.	Hipótesis General . . . . .	16
1.6.2.	Hipótesis Específicas . . . . .	16
1.6.3.	Matriz de Consistencia . . . . .	17
<b>2.</b>	<b>MARCO TEÓRICO</b>	<b>18</b>
2.1.	Antecedentes de la investigación . . . . .	18
2.1.1.	Deep Convolutional Neural Networks for Detecting COVID-19 Using Medical Images: A Survey ( <b>sharma2020deep</b> ) . . . . .	18
2.1.2.	Heart Disease Detection Using Machine Learning and Deep Learning Techniques ( <b>jiang2020heart</b> ) . . . . .	21
2.1.3.	Monitoring and Recognition of Heart Health using Heartbeat Classification with Deep Learning and IoT ( <b>arulkumar2023monitoring</b> ) . . . .	25
2.1.4.	Advances in Deep Learning: From Diagnosis to Treatment ( <b>huang2023advances</b> )	28
2.1.5.	A Study on Scope of Artificial Intelligence in Diagnostic Medicine ( <b>santhoshkumar2023</b> ) . . . . .	30
2.2.	Bases Teóricas . . . . .	33
2.2.1.	Machine Learning . . . . .	33
2.2.2.	Deep Learning . . . . .	34
2.2.3.	Redes Neuronales Convolutivas (CNNs) . . . . .	34
2.2.4.	Procesamiento de Imágenes Médicas . . . . .	35
2.2.5.	Técnicas de Preprocesamiento de Datos . . . . .	35
2.2.6.	Evaluación de Modelos de Machine Learning y Deep Learning . . . . .	36
2.2.7.	Retinopatía Diabética . . . . .	37
2.2.8.	Sistemas de Diagnóstico Asistido por Computadora (CAD) . . . . .	37
2.2.9.	Transferencia de Aprendizaje . . . . .	37
2.2.10.	Inteligencia Artificial en Medicina . . . . .	38
2.3.	Marco Conceptual . . . . .	39

2.3.1. Inteligencia Artificial (IA) . . . . .	39
2.3.2. Sistemas de Diagnóstico Asistido por Computadora (CAD) . . . . .	39
2.3.3. Base de Datos APTOS y Messidor . . . . .	39
2.3.4. Implementación Técnica . . . . .	39
<b>3. METODOLOGÍA DE LA INVESTIGACIÓN</b>	<b>41</b>
3.1. Diseño de la investigación . . . . .	41
3.1.1. Diseño no experimental . . . . .	41
3.1.2. Tipo explicativo . . . . .	41
3.1.3. Enfoque cuantitativo . . . . .	42
3.2. Población y muestra . . . . .	42
3.3. Operacionalización de Variables . . . . .	42
3.4. Instrumentos de medida . . . . .	43
3.5. Técnicas de recolección de datos . . . . .	43
3.6. Técnicas para el procesamiento y análisis de la información . . . . .	44
3.7. Cronograma de actividades y presupuesto . . . . .	44
<b>4. DESARROLLO DEL EXPERIMENTO</b>	<b>45</b>
4.1. X . . . . .	45
4.2. Y . . . . .	45
4.3. Z . . . . .	46
<b>5. ANÁLISIS Y DISCUSIÓN DE RESULTADOS</b>	<b>47</b>
5.1. X . . . . .	47
5.2. Y . . . . .	47
5.3. Z . . . . .	48
<b>6. CONCLUSIONES Y RECOMENDACIONES</b>	<b>49</b>



6.1. Conclusiones . . . . .	49
6.2. Recomendaciones . . . . .	49
<b>Anexos</b>	<b>50</b>

# Índice de Figuras

1.1. Predominio de la diabetes en Perú. Fuente: <b>idf2021</b> . . . . .	11
2.1. COVID-19 patterns to predict. Fuente: <b>sharma2020deep</b> . . . . .	19
2.2. COVID-19 detection related work. Fuente: <b>sharma2020deep</b> . . . . .	21
2.3. Tratamiento de la información propuesto. Fuente: <b>jiang2020heart</b> . . . . .	22
2.4. Modelo propuesto para el desarrollo. Fuente: <b>jiang2020heart</b> . . . . .	23
2.5. Rendimiento del modelo propuesto. Fuente: <b>jiang2020heart</b> . . . . .	25
2.6. Clasificación de los latidos. Fuente: <b>arulkumar2023monitoring</b> . . . . .	27
2.7. Modelo de CNN. Fuente: <b>arulkumar2023monitoring</b> . . . . .	27
2.8. Tabla de rendimiento del modelo. Fuente: <b>arulkumar2023monitoring</b> . . . . .	28
2.9. Clasificaciones de los diferentes uso a la IA en la medicina. Fuente: <b>santhoshkumar2023</b>	31
2.10. Aplicación de la IA en la rama de la SALUD. Fuente: <b>santhoshkumar2023</b> . . .	32
3.1. Prueba de Figura . . . . .	42

# Índice de Tablas

3.1. An example table. . . . .	44
4.1. An example table. . . . .	45
5.1. An example table. . . . .	47


# Capítulo 1

## PLANTEAMIENTO DEL PROBLEMA

### 1.1. Descripción de la Realidad Problemática

La retinopatía diabética (RD) constituye una complicación severa derivada de la diabetes, siendo la principal causa de pérdida de visión en adultos trabajadores en naciones desarrolladas. Esta afección impacta profundamente en la vida de las personas, no solo reduciendo su calidad de vida por la disminución visual, sino también imponiendo retos económicos significativos para los sistemas de salud debido al elevado precio de los tratamientos.

Globalmente, más de 537 millones de adultos viven con diabetes, y se estima que este número ascenderá a más de 780 millones para el año 2045. Un análisis exhaustivo muestra que alrededor del 34.6 % de estas personas desarrollarán alguna forma de RD, y un 7 % experimentará variantes severas como la retinopatía diabética proliferativa.



**Figura 1.1:** Predominio de la diabetes en Perú. Fuente: **idf2021**

La repercusión socioeconómica de la RD es vasta, incluyendo no solo los costes directos de los tratamientos sino también la reducción de la capacidad laboral de los afectados, lo que puede llevar a la pérdida de autonomía y al desarrollo de trastornos emocionales. Las opciones de tratamiento avanzadas, como las inyecciones intraoculares y las intervenciones quirúrgicas retinianas, suponen un lastre económico adicional tanto para los pacientes como para los sistemas sanitarios.

### **Acceso Desigual a la Atención Médica**

Existen notables disparidades en el acceso a los servicios médicos que pueden influir significativamente en la detección y tratamiento oportunos de la RD. Estas variaciones son particularmente evidentes entre distintas regiones y estratos socioeconómicos, y requieren ser abordadas en las políticas de salud para garantizar un tratamiento equitativo.

### **Impacto Psicológico y Comunitario**

El deterioro visual grave resultante de la RD afecta no solo a nivel individual, sino que también repercute en el entorno familiar y comunitario del paciente, exacerbando problemas psicosociales como el estrés y la depresión.

### **Costos Económicos a Nivel Macro y Micro**

Además de los gastos médicos directos, la RD acarrea costos indirectos por la pérdida de productividad laboral. Analizar estos aspectos desde una perspectiva global y local ofrece un panorama más claro para diseñar intervenciones efectivas y contextualizadas.

### **Innovaciones Tecnológicas en Detección y Tratamiento**

La revolución tecnológica en la salud ha introducido herramientas como la inteligencia artificial y la telemedicina, las cuales están cambiando la forma de diagnóstico y tratamiento de la RD. Estas innovaciones presentan nuevas oportunidades pero también desafíos, particularmente en términos de acceso equitativo.

**Políticas Públicas y Estrategias de Prevención** Es esencial evaluar críticamente las políticas y estrategias de salud pública vigentes, identificando áreas de mejora para fortalecer la prevención y el tratamiento de la RD, a través de campañas más efectivas y programas de detección mejorados.

### **Futuro y Sostenibilidad del Sistema de Salud**

Ante el incremento esperado en la prevalencia de la diabetes, es imperativo que los sistemas de salud se preparen para manejar esta carga creciente de manera eficiente y sostenible.

## 1.2. Problema General

¿De qué manera la implementación de un modelo de deep learning adecuado puede mejorar los resultados de los pre-diagnósticos de retinopatía diabética?

### 1.2.1. Problemas Específicos

- ¿Qué datos serán necesarios para entrenar modelos de deep learning en la pre-detección de la retinopatía diabética?
- ¿Cuál será la arquitectura de modelo de deep learning más efectiva para identificar características tempranas de la retinopatía diabética?
- ¿Qué métodos de preprocesamiento de imágenes serán utilizados para mejorar la precisión del modelo de deep learning en la detección de retinopatía diabética?
- ¿Qué métricas serán utilizadas para evaluar y comparar la efectividad de diferentes modelos de deep learning en la detección de la retinopatía diabética?

## 1.3. Objetivos de la Investigación

### 1.3.1. Objetivo General

Evaluar la implementación de un modelo de deep learning para mejorar los resultados de los pre-diagnósticos de retinopatía diabética.

### 1.3.2. Objetivos Específicos

- Identificar los datos necesarios para entrenar modelos de deep learning en la pre-detección de la retinopatía diabética.
- Determinar la arquitectura de modelo de deep learning más efectiva para identificar características tempranas de la retinopatía diabética.
- Evaluar los métodos de preprocesamiento de imágenes que mejoren la precisión del modelo de deep learning en la detección de retinopatía diabética.
- Definir y utilizar métricas para evaluar y comparar la efectividad de diferentes modelos de deep learning en la detección de la retinopatía diabética.

## 1.4. Justificación de la Investigación

### 1.4.1. Teórica

Este estudio se centra en la implementación de modelos de aprendizaje profundo para la detección temprana de la retinopatía diabética, una complicación prevalente y grave entre los diabéticos en Perú. Investigaciones recientes indican que la prevalencia de la retinopatía diabética en pacientes con diabetes tipo 2 es de 57.62 %, con una prevalencia de retinopatía diabética no proliferativa de 47.29 % y retinopatía diabética proliferativa de 10.33 % **yanhez2016prevalencia**. Este proyecto busca profundizar el entendimiento de cómo los avances en inteligencia artificial pueden mejorar significativamente la detección y el seguimiento precoz de esta afección.

La aplicación de técnicas avanzadas de aprendizaje profundo tiene el potencial de revolucionar la manera en que se detectan y manejan las enfermedades oculares. En el caso de la retinopatía diabética, los modelos de deep learning pueden ofrecer una precisión y eficiencia superiores en la identificación de signos tempranos, lo cual es crucial para la implementación de intervenciones oportunas. Este estudio no solo pretende validar la efectividad de estos modelos en un entorno clínico, sino también explorar sus limitaciones y desafíos asociados con su implementación **huang2023advances**.

### 1.4.2. Práctica

Desde un punto de vista práctico, este trabajo de investigación tiene el potencial de generar una mejora considerable en el método de pre-detección de la retinopatía diabética en Perú, donde comúnmente el diagnóstico ocurre en fases muy avanzadas. Implementar modelos de deep learning para la identificación temprana de la enfermedad podría facilitar intervenciones preventivas más efectivas, aliviar la carga económica sobre el sistema de salud y mejorar significativamente los resultados para los pacientes. Integrar esta tecnología en los sistemas públicos de salud mejoraría la accesibilidad y eficacia del diagnóstico de la retinopatía diabética, especialmente en zonas donde los recursos son escasos. Estudios recientes sobre el uso de deep learning en la detección de enfermedades cardíacas han demostrado su eficacia y precisión, lo que sugiere que métodos similares podrían ser beneficiosos para la detección de la retinopatía diabética **rajeswari2022heart; arulkumar2023monitoring**.

### 1.4.3. Metodológica

Metodológicamente, este estudio se distingue por su análisis exhaustivo y comparativo de diversos modelos de deep learning en función de su rendimiento con las variables comunes en el aprendizaje profundo y modelos predictivos. La metodología rigurosa que se aplicará no solo evaluará la precisión de estos modelos, sino que también explorará adaptaciones necesarias para maximizar su eficacia en el contexto específico de Perú.

Según **sharma2020deep**<empty citation>, los modelos de deep learning han demostrado ser altamente efectivos en la detección de enfermedades utilizando imágenes médicas. Este enfoque se aplicará para evaluar cómo estos modelos pueden ser adaptados para la detección temprana de la retinopatía diabética.

Además, **jiang2020heart**<empty citation> subrayan la importancia de ajustar los modelos de deep learning a los datos locales para mejorar su precisión y rendimiento. Esta investigación se centrará en adaptar y optimizar los modelos existentes para el contexto específico de Perú, proporcionando una base sólida para futuras aplicaciones en otras condiciones médicas y en el desarrollo de políticas de salud pública relacionadas con la implementación de nuevas tecnologías.

## 1.5. Delimitación del Estudio

### 1.5.1. Espacial

Este estudio se delimita al análisis de datos obtenidos de bases de datos internacionales reconocidas, específicamente el Messidor dataset y el APTOS 2019. Estas bases contienen imágenes de fondo de ojo de pacientes diabéticos, recolectadas bajo diversos estudios clínicos. La selección de estas bases de datos se debe a su amplio uso en la investigación académica y su relevancia para validar la precisión de modelos de deep learning en el contexto de la retinopatía diabética. Los tres modelos evaluados en este estudio incluyen el Customized Convolutional Neural Network (CCNN) de Mane et al. **mane2023customized**, el modelo propuesto por Mohanty et al. **mohanty2023using**, y el modelo de Deep Learning desarrollado por otro grupo de investigadores destacados en el campo **huang2023advances**. La investigación no involucrará la recolección de nuevos datos clínicos ni se realizarán pruebas directas con pacientes en Perú o cualquier otra región, concentrándose exclusivamente en el análisis técnico y comparativo de los datos ya existentes.



### **1.5.2. Temporal**

La investigación se llevará a cabo durante el año académico 2024, comenzando en enero y concluyendo en diciembre del mismo año. Este marco temporal ha sido seleccionado para alinear el estudio con el calendario académico, proporcionando un tiempo adecuado para cada fase del proyecto. Durante este período, se realizará la planificación detallada, la selección de modelos de deep learning, el procesamiento de datos, la ejecución de pruebas computacionales, y el análisis de los resultados. Este cronograma garantizará que todas las etapas del estudio se completen de manera organizada y eficiente.

### **1.5.3. Conceptual**

La investigación está enfocada en la evaluación técnica de modelos de deep learning específicos que han sido previamente desarrollados y aplicados en la detección de la retinopatía diabética. La delimitación conceptual incluye la validación de la efectividad de estos modelos en términos de precisión, sensibilidad, especificidad y otras métricas relevantes para el diagnóstico automatizado mediante imágenes. Se excluyen del estudio la creación de nuevos modelos de inteligencia artificial, cualquier intervención médica directa con pacientes, y la exploración de tratamientos para la retinopatía diabética. Este enfoque permite una concentración rigurosa en la evaluación del rendimiento de tecnologías específicas en un contexto controlado y basado en datos, proporcionando una evaluación crítica de su utilidad práctica y sus limitaciones.

## **1.6. Hipótesis**

### **1.6.1. Hipótesis General**

La implementación de un modelo de deep learning adecuado mejorará significativamente los resultados de los pre-diagnósticos de retinopatía diabética.

### **1.6.2. Hipótesis Específicas**

- Los datos seleccionados para entrenar modelos de deep learning serán suficientes y relevantes para mejorar la precisión en la pre-detección de la retinopatía diabética.

- La arquitectura de modelo de deep learning más efectiva identificará características tempranas de la retinopatía diabética con mayor precisión que las arquitecturas tradicionales.
- Los métodos de preprocesamiento de imágenes aplicados mejorarán la precisión del modelo de deep learning en la detección de la retinopatía diabética.
- Las métricas definidas y utilizadas para evaluar los modelos de deep learning proporcionarán una comparación clara y efectiva de la precisión y efectividad de diferentes modelos en la detección de la retinopatía diabética.

### **1.6.3. Matriz de Consistencia**

A continuación se presenta la matriz de consistencia elaborada para la presente investigación (véase Anexo ??).

## Capítulo 2

# MARCO TEÓRICO

### 2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis que abordan diversas técnicas y enfoques utilizados para afrontar problemas similares al de esta tesis. Vease el anexo 3 (insertar referencia)

#### 2.1.1. Deep Convolutional Neural Networks for Detecting COVID-19 Using Medical Images: A Survey (sharma2020deep)

##### 2.1.1.1. Planteamiento del Problema

En diciembre de 2019, el COVID-19, causado por el virus SARS-CoV-2, se propagó rápidamente, representando una grave amenaza para la salud pública a nivel mundial. La detección temprana y precisa es crucial para un tratamiento efectivo. Los métodos tradicionales, como las pruebas virales y de sangre, tienen limitaciones en sensibilidad y tiempo, por lo que se investiga el uso de deep learning aplicado a imágenes médicas (Rayos X, Tomografía Computarizada (CT) y Ultrasonido (US)) para mejorar la precisión y velocidad de diagnóstico.

##### 2.1.1.2. Objetivos

- Evaluar el uso de redes neuronales convolutivas (CNN) para mejorar la detección del COVID-19 a través de imágenes médicas.
- Comparar diferentes arquitecturas de CNN, como VGG, ResNet y DenseNet, en términos

de precisión y rapidez en el diagnóstico.

- Analizar la efectividad de la transferencia de aprendizaje utilizando modelos preentrenados en grandes bases de datos.


### 2.1.1.3. Fundamento Teórico

La implementación de deep learning en la medicina ha demostrado ser revolucionaria en el análisis de imágenes médicas, proporcionando una herramienta poderosa para la detección y diagnóstico de enfermedades. Las CNN son particularmente efectivas debido a su capacidad para reconocer patrones complejos en los datos de imagen. La transferencia de aprendizaje permite utilizar modelos preentrenados y ajustarlos para tareas específicas, mejorando significativamente la eficiencia y precisión del diagnóstico.

### 2.1.1.4. Metodología empleada por los autores

#### Modelos y Datasets Utilizados

- Se utilizaron CNNs (VGG16, DenseNet, ResNet) aplicadas a datasets como COVIDx.
- Los datos fueron preprocesados mediante normalización y aumento de datos para mejorar la calidad y variabilidad de las imágenes.



**Figura 2.1:** COVID-19 patterns to predict. Fuente: [sharma2020deep](#)

#### Evaluación de Modelos

- Los modelos fueron evaluados utilizando métricas como precisión, sensibilidad, especificidad y AUC.

- Se llevaron a cabo experimentos comparativos para determinar la arquitectura más efectiva en la detección del COVID-19.

### **Técnicas de Preprocesamiento**

- La normalización de imágenes fue esencial para asegurar que los datos estuvieran en un rango común, mejorando la estabilidad del entrenamiento.
- El aumento de datos incluyó técnicas como rotación, escalado y traslación para aumentar la variabilidad y robustez del modelo.

#### **2.1.1.5. Resultados obtenidos**

##### **Avances en la Detección Automatizada**

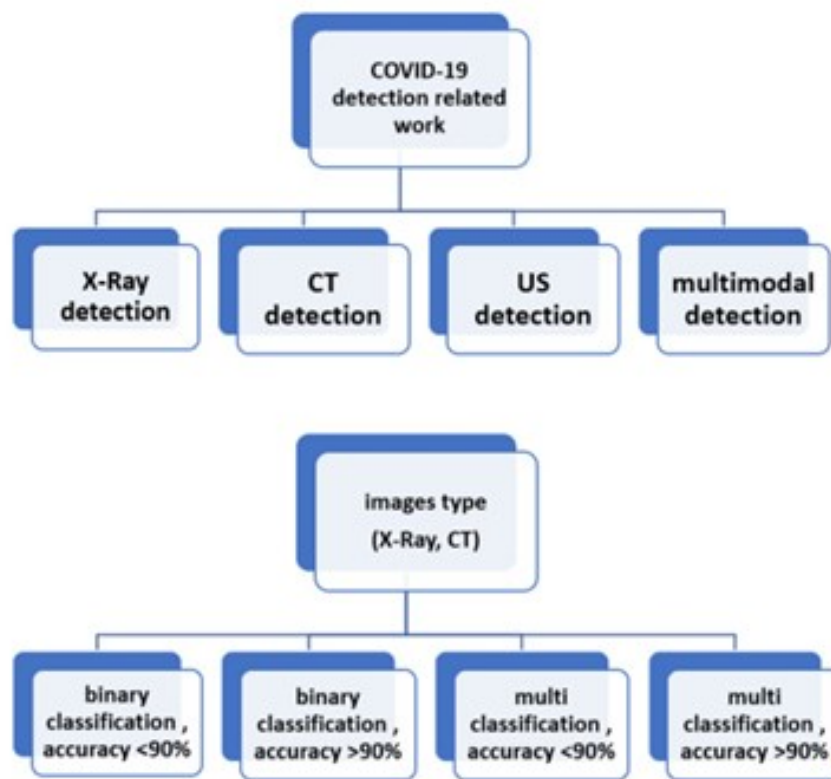
- Los modelos de deep learning demostraron igualar o superar la precisión de los métodos tradicionales, ofreciendo diagnósticos más rápidos y precisos.
- La arquitectura ResNet mostró una superioridad en términos de precisión y capacidad de generalización en comparación con VGG y DenseNet.

### **Impacto Clínico**

- La implementación de estos sistemas automatizados puede mejorar la detección temprana y reducir la carga de trabajo manual, permitiendo a los profesionales de la salud centrarse en casos más complejos.
- Los resultados sugieren una integración potencial de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala.

### **Futuras Direcciones**

- La investigación futura se centrará en la integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala.
- Se explorará la combinación de imágenes médicas con otros datos clínicos para mejorar aún más la precisión y eficiencia del diagnóstico.



**Figura 2.2:** COVID-19 detection related work. Fuente: sharma2020deep

## 2.1.2. Heart Disease Detection Using Machine Learning and Deep Learning Techniques (jiang2020heart)

### 2.1.2.1. Planteamiento del Problema

Las enfermedades del corazón son una de las principales causas de muerte a nivel mundial, con aproximadamente 17.9 millones de muertes registradas anualmente. Detectar la presencia de enfermedades del corazón de manera temprana es crucial para monitorear y tratar a los pacientes a tiempo y así salvar vidas. Esta investigación tiene como objetivo utilizar técnicas de aprendizaje automático y profundo para detectar enfermedades cardíacas, mejorando la precisión y la eficacia del diagnóstico.

### 2.1.2.2. Objetivos

- Desarrollar y evaluar modelos de aprendizaje automático y profundo para la detección de enfermedades cardíacas.
- Comparar el rendimiento de diferentes algoritmos de machine learning y deep learning.

- Optimizar los modelos para su implementación práctica en entornos clínicos.

### 2.1.2.3. Fundamento Teórico

La implementación de técnicas de machine learning (ML) y deep learning (DL) en la medicina ha permitido avances significativos en el diagnóstico de enfermedades. Estos métodos analizan grandes volúmenes de datos médicos y son capaces de identificar patrones complejos que pueden indicar la presencia de enfermedades. Las redes neuronales convolutivas (CNN) y otros modelos de ML, como SVM y logistic regression, son particularmente efectivos en la clasificación de datos médicos.

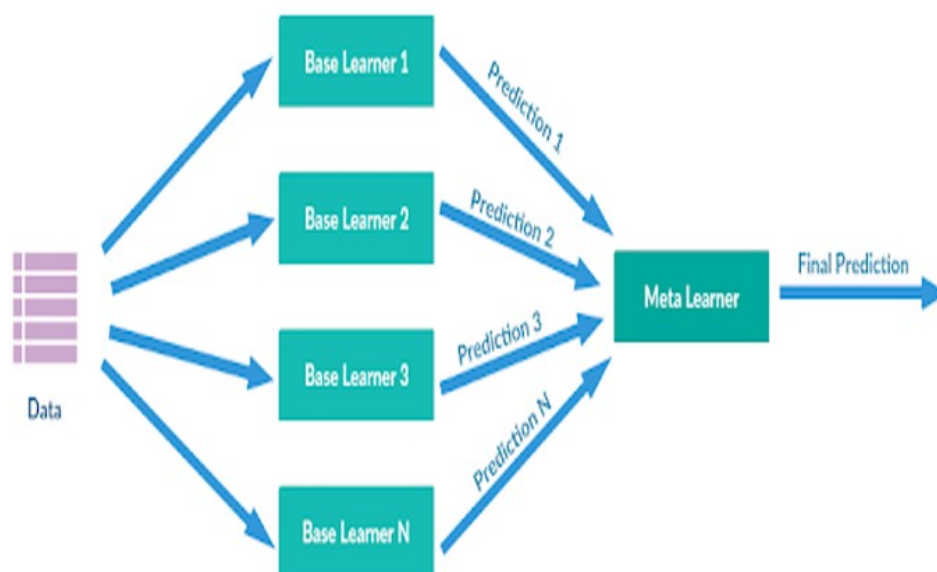
### 2.1.2.4. Metodología empleada por los autores

#### Modelos Utilizados

- Modelos de aprendizaje automático: SVM, logistic regression, decision tree.
- Modelos de aprendizaje profundo: FFNN, LSTM.

#### Origen de los Datos

- Los datos provinieron de un conjunto de datos con 1026 registros, que incluían diversas características médicas relevantes.



**Figura 2.3:** Tratamiento de la información propuesto. Fuente: **jiang2020heart**

## Validación y Evaluación

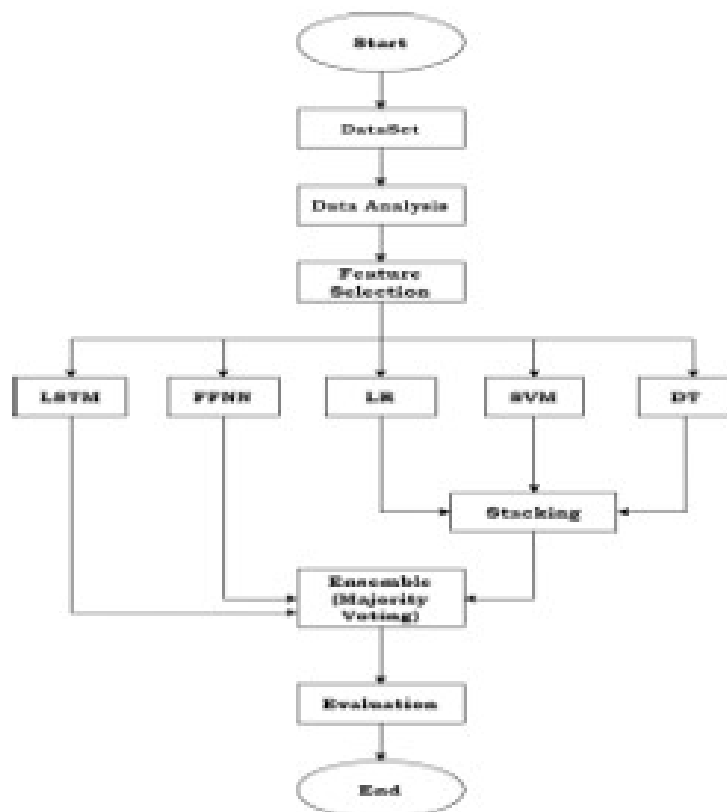
- Se aplicaron técnicas de validación cruzada para evaluar el rendimiento de los modelos.
- Las métricas utilizadas incluyeron precisión, sensibilidad, especificidad y AUC para una evaluación exhaustiva.

## Selección y Preprocesamiento de Características

- Métodos utilizados: matriz de correlación, puntaje de Fisher.
- Normalización de datos para asegurar que todas las características estuvieran en el mismo rango.

## Optimización de Modelos

- Ajuste fino de hiperparámetros para optimizar el rendimiento.
- Cuantificación de parámetros para reducir el tamaño del modelo y mejorar la eficiencia del entrenamiento.



**Figura 2.4:** Modelo propuesto para el desarrollo. Fuente: [jiang2020heart](#)



### **2.1.2.5. Resultados obtenidos**

#### **Precisión de los Modelos**

- Los modelos de deep learning, en particular FFNN y LSTM, mostraron una alta precisión en la detección de enfermedades cardíacas.
- Los modelos de machine learning, como SVM y logistic regression, también demostraron ser efectivos, aunque con menor precisión comparada.

#### **Eficiencia y Aplicabilidad Clínica**

- La implementación de estos modelos en sistemas automatizados puede reducir significativamente la carga de trabajo manual en entornos clínicos.
- Los modelos demostraron ser capaces de proporcionar diagnósticos rápidos y precisos, facilitando la toma de decisiones médicas.

#### **Direcciones Futuras**

- Integrar estos modelos en sistemas de salud reales para pruebas clínicas a gran escala.
- Explorar la combinación de datos médicos con otras fuentes de información para mejorar la precisión y eficiencia del diagnóstico.

Models	ML Stacking	Ensemble
Accuracy	86.14	87.21
Precision	83.40	84.31
Recall	91.04	92.20
F1-Score	87.01	88.07
ROC-AUC	86.01	86.03

**Figura 2.5:** Rendimiento del modelo propuesto. Fuente: **jiang2020heart**

### **2.1.3. Monitoring and Recognition of Heart Health using Heartbeat Classification with Deep Learning and IoT (arulkumar2023monitoring)**

#### **2.1.3.1. Planteamiento del Problema**

Las enfermedades cardiovasculares, como la arritmia y el infarto de miocardio, representan graves problemas de salud que pueden ser mortales si no se detectan y tratan a tiempo. La detección temprana y precisa es crucial para un tratamiento efectivo. El objetivo de este estudio es utilizar técnicas de aprendizaje profundo y el Internet de las cosas (IoT) para mejorar la detección y clasificación de latidos cardíacos, lo que permite identificar problemas de salud cardíaca de manera automática y precisa.

#### **2.1.3.2. Objetivos**

- Utilizar técnicas de deep learning para mejorar la detección de arritmias y otras enfermedades cardíacas.
- Implementar IoT para la recolección de datos en tiempo real y monitoreo continuo de la salud cardíaca.

- Evaluar la precisión y efectividad del sistema propuesto utilizando el dataset MIT-BIH arrhythmia.

### 2.1.3.3. Fundamento Teórico

El avance en las técnicas de aprendizaje profundo y la inteligencia artificial ha permitido mejorar significativamente el diagnóstico médico, especialmente en la clasificación de señales de electrocardiograma (ECG). El uso de redes neuronales convolutivas (CNN) y otras arquitecturas de deep learning permite la detección precisa de patrones en las señales cardíacas, facilitando la identificación de arritmias y otras anomalías.

### 2.1.3.4. Metodología empleada por los autores

#### Adquisición y Procesamiento de Datos

- **Sensores Médicos:** Los parámetros biomédicos se calculan utilizando sensores para proporcionar mediciones precisas de los parámetros físicos. Estos datos se obtienen mediante dispositivos portátiles para monitorear la salud del corazón y detectar anomalías en su funcionamiento.
- **Procesamiento de Datos:** Incluye la recolección de datos de señales ECG a través de conductores y electrodos. El ruido se elimina mediante la Transformada Wavelet Discreta (DWT), lo que mejora la calidad del conjunto de datos.

#### Clasificación y Análisis de Datos

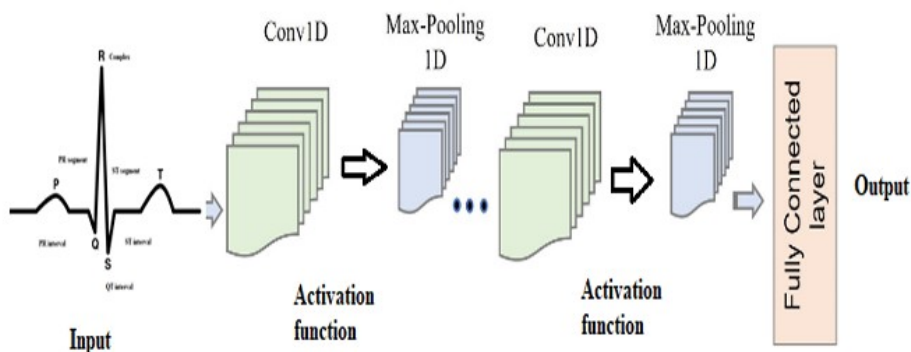
- **Redes Neuronales Convolutivas (CNN):** Utilización de modelos CNN 1D para aplicaciones en tiempo real, compuestos por varias capas utilizadas para el procesamiento y extracción de características.
- **Memoria Bidireccional a Largo Plazo (Bi-LSTM):** Modelo que incluye direcciones hacia adelante y hacia atrás para la acumulación y procesamiento de datos, mejorando la precisión del etiquetado de secuencias.



**Figura 2.6:** Clasificación de los latidos. Fuente: [arulkumar2023monitoring](#)

## Evaluación del Sistema

- **Evaluación del Desempeño:** Uso de métricas como precisión, sensibilidad, especificidad y AUC para evaluar la efectividad del sistema.
- **Validación y Pruebas:** El sistema se entrenó y validó utilizando el dataset MIT-BIH arrhythmia, obteniendo altos niveles de precisión y eficiencia.



**Fig 16.** CNN Model

**Figura 2.7:** Modelo de CNN. Fuente: [arulkumar2023monitoring](#)

### 2.1.3.5. Resultados obtenidos

- **Avances en la Detección Automatizada:** Los modelos de deep learning demostraron ser altamente precisos en la detección de arritmias y otras enfermedades cardíacas, con una precisión del 99.98
- **Impacto en la Salud Clínica:** La implementación de estos sistemas automatizados mejora la detección temprana y reduce la carga de trabajo manual, permitiendo a los profesionales de la salud centrarse en casos más complejos.
- **Futuras Direcciones:** La investigación futura se centrará en la integración de estos modelos en sistemas de salud reales para pruebas clínicas a gran escala y la exploración de nuevas técnicas de procesamiento de señales y aprendizaje profundo.

Parameter	Train values	Valid values	Test values
Accuracy	100%	99.97%	99.98%
Recall	100%	99.94%	99.96%
Specificity	100%	99.98%	99.98%
Precision	99.98%	99.98%	99.93%

**Figura 2.8:** Tabla de rendimiento del modelo. Fuente: [arulkumar2023monitoring](#)

## 2.1.4. Advances in Deep Learning: From Diagnosis to Treatment ([huang2023advances](#))

### 2.1.4.1. Planteamiento del Problema

El aprendizaje profundo ha revolucionado el campo del diagnóstico y tratamiento médico, alcanzando niveles de precisión comparables a los de los profesionales médicos en diversas tareas diagnósticas. Este estudio investiga el uso de modelos de aprendizaje profundo para integrar diferentes formas de datos médicos y proporcionar sugerencias diagnósticas y de tratamiento precisas y en tiempo real.

### 2.1.4.2. Objetivos

- Explorar la integración de modelos de aprendizaje profundo en sistemas de diagnóstico y tratamiento médico.
- Evaluar la efectividad de los modelos de aprendizaje profundo en la mejora de la precisión diagnóstica y la eficiencia del tratamiento.

- Analizar la colaboración entre médicos y máquinas en el contexto de la atención médica personalizada.

#### **2.1.4.3. Fundamento Teórico**

El uso de deep learning en la medicina ha crecido exponencialmente en los últimos años, logrando una precisión similar a la de los médicos en diversas tareas diagnósticas. Los modelos de deep learning pueden integrar diferentes formas de datos médicos, como imágenes, registros electrónicos de salud, genómica y texto médico, para proporcionar salidas útiles basadas en la información del paciente. Estos modelos tienen el potencial de transformar los sistemas de diagnóstico y tratamiento al proporcionar capacidades de razonamiento en tiempo real en escenarios quirúrgicos complejos.

#### **2.1.4.4. Metodología empleada por los autores**

##### **Modelos y Datasets Utilizados**

- Evaluación de modelos avanzados de deep learning como R-CNN, U-Net y GPT-4 aplicados a conjuntos de datos médicos variados.
- Integración de diversas formas de datos médicos, incluyendo imágenes médicas, registros electrónicos de salud, y datos genómicos.

##### **Desarrollo de Modelos de Fundamento Médico**

- Utilización de grandes conjuntos de datos de entrenamiento para mejorar la capacidad de razonamiento de los modelos.
- Implementación de modelos que integran múltiples formas de información médica para proporcionar diagnósticos y sugerencias de tratamiento precisas.

##### **Automatización en Procedimientos Quirúrgicos**

- Uso de aprendizaje por refuerzo para permitir la operación autónoma de robots durante procedimientos quirúrgicos simples.
- Desarrollo de dispositivos quirúrgicos integrados con tecnología de modelo de fundamento médico para mejorar la toma de decisiones diagnósticas y terapéuticas.

#### **2.1.4.5. Resultados obtenidos**

##### **Avances en Diagnóstico y Tratamiento Automatizado**

- Los modelos de deep learning han demostrado igualar o superar la precisión de los métodos tradicionales en tareas diagnósticas, ofreciendo diagnósticos y sugerencias de tratamiento más rápidos y precisos.
- Los modelos de fundamento médico muestran un gran potencial para realizar tareas más diversas y desafiantes al integrar múltiples formas de datos médicos.

##### **Colaboración entre Médicos y Máquinas**

- La implementación de sistemas automatizados puede mejorar la eficiencia y precisión del diagnóstico, reduciendo la carga de trabajo manual de los profesionales de la salud.
- Los médicos deben comprender los principios y riesgos técnicos de los métodos de deep learning y dominar los procedimientos para integrarlos en la práctica clínica.

##### **Futuras Direcciones**

- La investigación futura se centrará en la integración de modelos de fundamento médico en sistemas de salud reales para pruebas clínicas a gran escala.
- Desarrollo de sistemas autónomos de diagnóstico y tratamiento que puedan operar con mínima intervención humana, mejorando la precisión y personalización de la atención médica.

#### **2.1.5. A Study on Scope of Artificial Intelligence in Diagnostic Medicine (santhoshkumar2023)**

##### **2.1.5.1. Planteamiento del Problema**

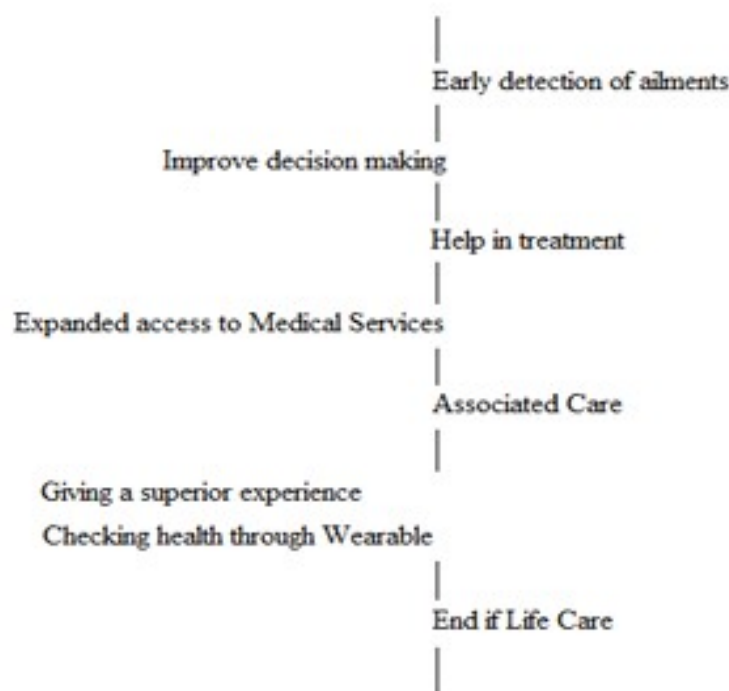
El uso de técnicas de inteligencia artificial (IA) está mejorando significativamente la atención al paciente y los sistemas de salud. La capacidad de la IA para analizar grandes cantidades de datos médicos y reconocer patrones ha mostrado un potencial considerable en el diagnóstico de enfermedades. Este estudio analiza cómo las técnicas de IA, incluyendo el aprendizaje automático y profundo, pueden integrarse en la medicina diagnóstica para mejorar la precisión del diagnóstico y optimizar la atención al paciente.

### 2.1.5.2. Objetivos

- Evaluar el impacto de la IA en el diagnóstico médico y su capacidad para mejorar la precisión y eficiencia en la detección de enfermedades.
- Analizar las aplicaciones actuales de la IA en la medicina diagnóstica, incluyendo el reconocimiento de imágenes, procesamiento del lenguaje natural (NLP) y análisis de datos genómicos.
- Examinar los desafíos éticos y técnicos asociados con la implementación de la IA en la atención médica.

### 2.1.5.3. Fundamento Teórico

La adopción de tecnologías avanzadas como la inteligencia artificial (IA) está provocando un cambio rápido en el sector sanitario. La IA se utiliza para crear nuevos sistemas clínicos, mejorar los datos y registros de los pacientes, e identificar diversas enfermedades. La integración de la IA con otras tecnologías digitales tiene el potencial de transformar por completo el sector sanitario, mejorando los resultados de los pacientes, reduciendo los costos y permitiendo una atención más individualizada y eficaz.



**Figura 2.9:** Clasificaciones de los diferentes usos de la IA en la medicina. Fuente: **santhoshkumar2023**



#### 2.1.5.4. Metodología empleada por los autores

##### Reconocimiento de Imágenes

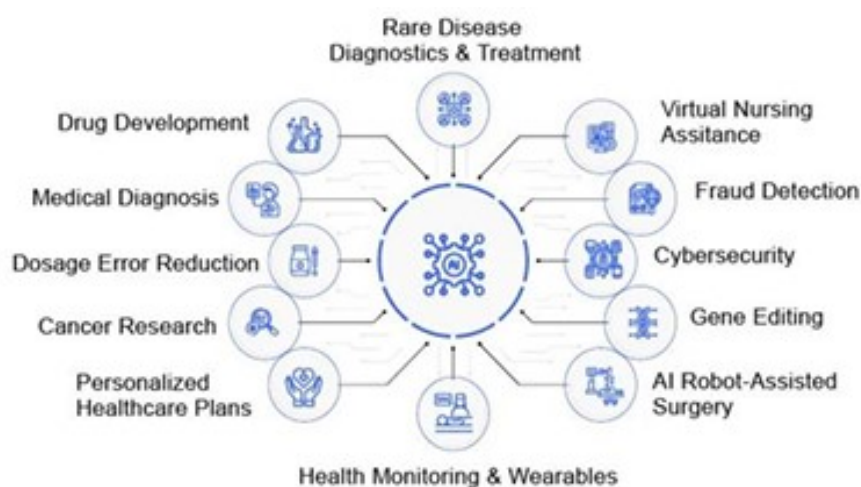
- Uso de algoritmos de IA para analizar imágenes médicas como radiografías, tomografías computarizadas (CT) y resonancias magnéticas (MRI).
- Identificación de anomalías que podrían ser indicativas de enfermedades, como el cáncer de piel y el cáncer de pulmón.

##### Procesamiento del Lenguaje Natural (NLP)

- Análisis de registros de salud electrónicos (EHR) y patrones de lenguaje para identificar indicios de enfermedades.
- Detección temprana de sepsis y signos iniciales de la enfermedad de Alzheimer en patrones de habla.

##### Análisis de Datos Genómicos

- Uso de IA para analizar datos genéticos y encontrar mutaciones o variaciones que podrían indicar riesgos de enfermedades.
- Identificación de marcadores genéticos para el cáncer de mama y diagnóstico de trastornos genéticos raros.



**Figura 2.10:** Aplicación de la IA en la rama de la SALUD. Fuente: **santhoshkumar2023**

### 2.1.5.5. Resultados obtenidos

#### Avances en la Detección Automatizada

- La IA ha mostrado un potencial considerable para mejorar la precisión y rapidez del diagnóstico de enfermedades.
- Los sistemas de IA pueden ayudar a reducir falsos positivos y falsos negativos, mejorando los resultados de los pacientes.

#### Impacto Clínico

- La implementación de IA puede mejorar la toma de decisiones clínicas y reducir la carga de trabajo manual de los profesionales de la salud.
- La IA tiene el potencial de transformar la atención médica al permitir diagnósticos más precisos y tratamientos personalizados.

#### Desafíos y Futuras Direcciones

- Asegurar la privacidad y seguridad de los datos del paciente sigue siendo un desafío importante.
- La investigación futura se centrará en el desarrollo de prácticas éticas y responsables para la implementación de la IA en la atención médica.

## 2.2. Bases Teóricas

### 2.2.1. Machine Learning

El machine learning es un campo de la inteligencia artificial que se dedica a crear algoritmos capaces de aprender y mejorar a partir de datos, en lugar de seguir instrucciones predefinidas. Estos algoritmos identifican patrones y relaciones en los datos, lo que les permite hacer predicciones y tomar decisiones con una precisión cada vez mayor. Los problemas en machine learning se dividen principalmente en cinco categorías:

- **Regresión:** Utilizada para predecir valores continuos. Por ejemplo, estimar los niveles de glucosa en sangre.

- **Clasificación:** Se enfoca en asignar etiquetas a los datos basados en categorías. Por ejemplo, diagnosticar retinopatía diabética (presente o ausente).
- **Simulación:** Modela el comportamiento de sistemas complejos para prever resultados futuros. Por ejemplo, simular la progresión de enfermedades oculares.
- **Optimización:** Busca encontrar la mejor solución entre muchas posibles, bajo ciertas restricciones. Por ejemplo, optimizar las dosis de medicamentos.
- **Clusterización:** Agrupa datos en clusters basados en similitudes inherentes. Por ejemplo, segmentar pacientes según el riesgo de desarrollar retinopatía diabética.

Además, el machine learning se clasifica en subdisciplinas como aprendizaje supervisado, no supervisado, semi-supervisado y por refuerzo, cada una adecuada para diferentes tipos de problemas y datos.

### 2.2.2. Deep Learning

El deep learning es una subcategoría avanzada del machine learning que utiliza redes neuronales profundas, compuestas por múltiples capas, para modelar patrones complejos y no lineales en grandes volúmenes de datos. Este enfoque ha revolucionado numerosos campos, especialmente el análisis de imágenes médicas. Las redes neuronales convolutivas (CNNs) son particularmente efectivas en este contexto debido a su capacidad para capturar características espaciales y estructurales de las imágenes.

- **Transferencia de Aprendizaje:** Técnica que permite utilizar modelos preentrenados en grandes conjuntos de datos y adaptarlos a tareas específicas con menos datos etiquetados, mejorando la eficiencia del entrenamiento.
- **Regularización:** Métodos como dropout y batch normalization son cruciales para evitar el sobreajuste y mejorar la generalización de los modelos.
- **Arquitecturas Avanzadas:** Modelos como ResNet, VGG y DenseNet han mostrado resultados sobresalientes en la clasificación y segmentación de imágenes médicas.

### 2.2.3. Redes Neuronales Convolutivas (CNNs)

Las CNNs son una clase específica de redes neuronales diseñadas para procesar datos con una estructura de cuadrícula, como las imágenes. Estas redes se componen de:

- **Capas Convolucionales:** Filtran las imágenes para extraer características esenciales como bordes, texturas y formas.
- **Capas de Pooling:** Reducen la dimensionalidad de las características, conservando la información relevante y disminuyendo la carga computacional.
- **Capas Fully Connected:** Combinan las características extraídas para clasificar o predecir resultados específicos.
- **Capas de Normalización:** Mejoran la estabilidad y eficiencia del entrenamiento mediante la normalización de los datos a través de las capas.

Las CNNs han demostrado ser particularmente efectivas en tareas de reconocimiento y diagnóstico de imágenes médicas, superando con frecuencia a los métodos tradicionales.

#### 2.2.4. Procesamiento de Imágenes Médicas

El procesamiento de imágenes médicas es fundamental para el análisis preciso y eficaz en el diagnóstico de enfermedades. Este proceso incluye varias etapas:

- **Preprocesamiento:** Técnicas como la normalización, el aumento de datos y la eliminación de ruido mejoran la calidad de las imágenes y la robustez de los modelos.
- **Segmentación de Imágenes:** Separa las áreas de interés (como lesiones oculares) del fondo de la imagen, facilitando un análisis detallado.
- **Extracción de Características:** Identifica y extrae características relevantes para el diagnóstico, como la forma, el tamaño y la textura de las anomalías.
- **Análisis de Imágenes:** Utiliza algoritmos avanzados para interpretar las características extraídas y realizar diagnósticos precisos.

Estas técnicas son esenciales para la detección temprana y el tratamiento efectivo de la retinopatía diabética.

#### 2.2.5. Técnicas de Preprocesamiento de Datos

La calidad y la consistencia de los datos son cruciales para el entrenamiento efectivo de modelos de machine learning y deep learning. Las técnicas de preprocesamiento más comunes incluyen:

- **Normalización:** Ajusta los valores de los datos a un rango común, mejorando la estabilidad del modelo durante el entrenamiento.
- **Estandarización:** Transforma los datos para tener una media cero y una desviación estándar uno, lo cual es útil para modelos sensibles a la escala de los datos.
- **Aumento de Datos (Data Augmentation):** Genera nuevas muestras de datos a partir de las existentes mediante transformaciones como rotación, escalado y traslación, incrementando así la variabilidad y robustez del modelo.
- **Eliminación de Ruido:** Utiliza técnicas como filtros de mediana y gaussianos para limpiar las imágenes y mejorar la calidad de los datos.

Estas técnicas son especialmente importantes en el contexto de imágenes médicas, donde los datos pueden ser limitados y de calidad variable.

### 2.2.6. Evaluación de Modelos de Machine Learning y Deep Learning

La evaluación rigurosa de los modelos es crucial para garantizar su efectividad y fiabilidad en aplicaciones médicas. Las métricas comunes incluyen:

- **Precisión:** Proporción de verdaderos positivos entre el total de predicciones positivas.
- **Sensibilidad (Recall):** Capacidad del modelo para identificar correctamente los casos positivos.
- **Especificidad:** Capacidad del modelo para identificar correctamente los casos negativos.
- **AUC (Área Bajo la Curva ROC):** Medida de la capacidad del modelo para diferenciar entre clases.
- **F1-score:** Media armónica de la precisión y la sensibilidad, proporcionando una medida balanceada del rendimiento del modelo.

Además, técnicas de validación como la validación cruzada y el conjunto de validación son fundamentales para evaluar la capacidad de generalización del modelo y evitar el sobreajuste.

### 2.2.7. Retinopatía Diabética

La retinopatía diabética es una complicación común de la diabetes que afecta los vasos sanguíneos de la retina, pudiendo llevar a la pérdida de visión si no se detecta y trata a tiempo. Existen varios tipos de retinopatía diabética:

- **Retinopatía Diabética No Proliferativa (RDNP):** Etapa temprana caracterizada por microaneurismas y hemorragias retinianas.
- **Retinopatía Diabética Proliferativa (RDP):** Etapa avanzada donde se forman nuevos vasos sanguíneos anormales en la retina, aumentando el riesgo de desprendimiento de retina.

La detección temprana es crucial y se realiza mediante exámenes de fondo de ojo y angiografía fluoresceínica, métodos tradicionales de diagnóstico.

### 2.2.8. Sistemas de Diagnóstico Asistido por Computadora (CAD)

Los sistemas CAD son herramientas que utilizan algoritmos de inteligencia artificial para ayudar a los médicos en el diagnóstico de enfermedades. En oftalmología, los sistemas CAD han demostrado ser altamente efectivos en la detección temprana de la retinopatía diabética, proporcionando:

- **Análisis Automático:** Evaluación rápida y precisa de imágenes retinianas.
- **Segunda Opinión:** Ayuda a los médicos a confirmar diagnósticos y tomar decisiones informadas.
- **Monitorización Continua:** Seguimiento de la progresión de la enfermedad a lo largo del tiempo.

Estos sistemas mejoran significativamente la precisión y eficiencia del diagnóstico, reduciendo la carga de trabajo manual de los profesionales de la salud.

### 2.2.9. Transferencia de Aprendizaje

La transferencia de aprendizaje es una técnica poderosa que permite utilizar modelos preentrenados en grandes conjuntos de datos y adaptarlos a tareas específicas mediante fine-

tuning. Esto es especialmente útil en medicina, donde los datos etiquetados pueden ser limitados. Ventajas de la transferencia de aprendizaje:

- **Reducción del Tiempo de Entrenamiento:** Aprovecha el conocimiento de modelos pre-entrenados para acelerar el entrenamiento.
- **Mejora del Rendimiento:** Los modelos preentrenados suelen tener mejor rendimiento en tareas específicas después del fine-tuning.
- **Eficiencia de Datos:** Permite obtener buenos resultados incluso con conjuntos de datos limitados.

Esta técnica es ampliamente utilizada en el diagnóstico de imágenes médicas, incluyendo la retinopatía diabética.

### 2.2.10. Inteligencia Artificial en Medicina

La inteligencia artificial ha revolucionado el campo del diagnóstico médico, permitiendo diagnósticos más rápidos y precisos. Los avances en IA han mejorado significativamente la atención médica y se espera que continúen transformando el campo de la salud en el futuro. Aplicaciones notables incluyen:

- **Diagnóstico por Imágenes:** Análisis automatizado de radiografías, tomografías y resonancias magnéticas.
- **Predicción de Enfermedades:** Modelos predictivos que identifican individuos en riesgo de desarrollar enfermedades crónicas.
- **Medicina Personalizada:** Tratamientos adaptados a las características genéticas y clínicas de cada paciente.
- **Asistencia Robótica:** Sistemas robóticos que asisten en cirugías y otros procedimientos médicos.

La IA no solo mejora la precisión y eficiencia del diagnóstico, sino que también abre nuevas posibilidades para la investigación y el desarrollo de tratamientos innovadores.

## 2.3. Marco Conceptual

### 2.3.1. Inteligencia Artificial (IA)

La inteligencia artificial (IA) es una disciplina de las ciencias computacionales dedicada a desarrollar sistemas que pueden realizar tareas que típicamente requieren inteligencia humana. Esto incluye el reconocimiento de voz, toma de decisiones, y análisis de datos, entre otros. Los sistemas de IA son capaces de aprender y adaptarse a través de algoritmos que procesan grandes volúmenes de datos, mejorando su desempeño con el tiempo.

### 2.3.2. Sistemas de Diagnóstico Asistido por Computadora (CAD)

Los sistemas CAD utilizan algoritmos de inteligencia artificial para asistir a los médicos en el diagnóstico de enfermedades. En oftalmología, estos sistemas han demostrado ser altamente efectivos en la detección temprana de la retinopatía diabética, proporcionando análisis automáticos rápidos y precisos, y ayudando a los médicos a confirmar diagnósticos y tomar decisiones informadas. Los beneficios incluyen:

- **Análisis Automático:** Evaluación rápida y precisa de imágenes retinianas.
- **Segunda Opinión:** Ayuda a los médicos a confirmar diagnósticos.
- **Monitorización Continua:** Seguimiento de la progresión de la enfermedad.

### 2.3.3. Base de Datos APTOS y Messidor

Estas bases de datos contienen imágenes de fondo de ojo etiquetadas con diferentes grados de retinopatía diabética, utilizadas para entrenar y evaluar modelos de deep learning en la detección de esta enfermedad. Son recursos cruciales para la investigación y desarrollo de sistemas de diagnóstico asistido por computadora.

### 2.3.4. Implementación Técnica

#### 2.3.4.1. Selección de la Plataforma de Desarrollo

Para la implementación de modelos de deep learning en la detección de retinopatía diabética, las plataformas recomendadas incluyen:



- **TensorFlow:** Una biblioteca open-source de Google para el desarrollo y entrenamiento de modelos de machine learning y deep learning.
- **Keras:** Una API de alto nivel para construir y entrenar modelos de deep learning, que funciona sobre TensorFlow.
- **PyTorch:** Una biblioteca de machine learning desarrollada por Facebook, popular por su flexibilidad y facilidad de uso.

#### 2.3.4.2. Diseño de la Arquitectura del Modelo

- **Frontend:** No aplica en este contexto, ya que se enfoca en la construcción del modelo de deep learning.
- **Backend:** El servidor que aloja el modelo de deep learning, procesa las imágenes retinianas y genera diagnósticos.
- **Integraciones:** Con sistemas de información médica y bases de datos de imágenes para obtener y almacenar datos de entrenamiento y validación.

#### 2.3.4.3. Desarrollo del Modelo

- **Entrenamiento del Modelo de Deep Learning:** Utilizar datos de imágenes retinianas etiquetadas para entrenar el modelo, asegurando que pueda detectar diferentes grados de retinopatía diabética.
- **Desarrollo de la Base de Conocimientos:** Compilar y estructurar la información médica relevante y las imágenes etiquetadas en una base de datos accesible por el modelo.
- **Pruebas y Validación:** Realizar pruebas exhaustivas para asegurar la precisión y fiabilidad del modelo, incluyendo pruebas con datos no vistos previamente para evaluar la capacidad de generalización.

## Capítulo 3

# METODOLOGÍA DE LA INVESTIGACIÓN

### 3.1. Diseño de la investigación

En esta sección del documento se explicará cual es el diseño, el tipo y el enfoque del trabajo de investigación, así como también la población y la muestra.

#### 3.1.1. Diseño no experimental

El diseño es no experimental longitudinal, ya que las variables no serán manipuladas y serán analizadas tal como se encuentran. Es decir, tanto los datos textuales (noticias) y el precio del cobre serán analizados sin ningún cambio aplicando técnicas de procesamiento de lenguaje natural y algoritmos de aprendizaje automático con la finalidad de crear un modelo productivo robusto y facilitar la predicción del cobre. Asimismo, la recolección de datos que se realizará será en un determinado periodo de tiempo.

#### 3.1.2. Tipo explicativo


El alcance de la presente investigación es explicativo debido a que se busca explicar el comportamiento volátil del precio del cobre en base a noticias de periódicos digitales y además predecirlo.

### 3.1.3. Enfoque cuantitativo

El enfoque esta investigación es cuantitativo dado que se empleará técnicas del procesamiento de lenguaje natural (NLP), las cuales conllevan a procesar los datos de tipo textual a numéricos (vectores de características) y con ello posteriormente usar técnicas estadísticas como la regresión lineal para la predicción del precio del cobre.

## 3.2. Población y muestra

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit. La Figura 3.1 y el Cuadro 3.1



**Figura 3.1:** Prueba de Figura

## 3.3. Operacionalización de Variables

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus

mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

### 3.4. Instrumentos de medida

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat

- muscle and fat cells remove glucose from the blood,
- cells breakdown glucose via glycolysis and the citrate cycle, storing its energy in the form of ATP,
- liver and muscle store glucose as glycogen as a short-term energy reserve,
- adipose tissue stores glucose as fat for long-term energy reserve, and
- cells use glucose for protein synthesis.

### 3.5. Técnicas de recolección de datos

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

L<sup>A</sup>T<sub>E</sub>X is great at typesetting mathematics. Let  $X_1, X_2, \dots, X_n$  be a sequence of independent and identically distributed random variables with

$$S_n = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{1}{n} \sum_i^n X_i \quad (\text{Ecuación 3.1})$$

La Ecuación [Ecuación 3.1](#) denote their mean. Then as  $n$  approaches infinity, the random variables

$$\sqrt{n}(S_n - \mu)$$

converge in distribution to a normal  $\mathcal{N}(0, \sigma^2)$ .

## 3.6. Técnicas para el procesamiento y análisis de la información

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

You can make lists with automatic numbering ...

1. Like this,
2. and like this.

... or bullet points ...

- Like this,
- and like this.

## 3.7. Cronograma de actividades y presupuesto

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

**Tabla 3.1:** An example table.

# Capítulo 4

## DESARROLLO DEL EXPERIMENTO

### 4.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

### 4.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

**Tabla 4.1:** An example table.

### 4.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

El paper es citado y el otro paper .

## Capítulo 5

# ANÁLISIS Y DISCUSIÓN DE RESULTADOS

### 5.1. X

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

### 5.2. Y

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

Item	Quantity
Widgets	42
Gadgets	13

**Tabla 5.1:** An example table.



### 5.3. Z

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

## Capítulo 6

# CONCLUSIONES Y RECOMENDACIONES

### 6.1. Conclusiones

Hello, here is some text without a meaning. This text should show what a printed text will look like at this place. If you read this text, you will get no information. Really? Is there no information? Is there a difference between this text and some nonsense like “Huardest gefburn? Kjift ”not at all!...

### 6.2. Recomendaciones

Nisi porta lorem mollis aliquam ut porttitor leo. Aenean pharetra magna ac placerat vestibulum. Est placerat in egestas erat imperdiet sed euismod. Velit euismod in pellentesque massa placerat. Enim praesent elementum facilisis leo vel fringilla. Ante in nibh mauris cursus mattis molestie a iaculis. Erat pellentesque adipiscing commodo elit at imperdiet dui accumsan sit. Porttitor lacus luctus accumsan tortor posuere ac ut. Tortor at auctor urna nunc id. A iaculis at erat pellentesque adipiscing commodo elit.

## **Anexos**

## **Anexos A**

### **Anexo I: Matriz de Consistencia**

PROBLEMAS	OBJETIVOS	HIPÓTESIS
¿De qué manera la implementación de un modelo de deep learning adecuado puede mejorar los resultados de los pre-diagnósticos de retinopatía diabética?	Evaluar la implementación de un modelo de deep learning para mejorar los resultados de los pre-diagnósticos de retinopatía diabética.	La implementación de un modelo de deep learning adecuado mejorará significativamente los resultados de los pre-diagnósticos de retinopatía diabética.
¿Qué datos serán necesarios para entrenar modelos de deep learning en la pre-detección de la retinopatía diabética?	Identificar los datos necesarios para entrenar modelos de deep learning en la pre-detección de la retinopatía diabética.	Los datos seleccionados para entrenar modelos de deep learning serán suficientes y relevantes para mejorar la precisión en la pre-detección de la retinopatía diabética.
¿Cuál será la arquitectura de modelo de deep learning más efectiva para identificar características tempranas de la retinopatía diabética?	Determinar la arquitectura de modelo de deep learning más efectiva para identificar características tempranas de la retinopatía diabética.	La arquitectura de modelo de deep learning más efectiva identificará características tempranas de la retinopatía diabética con mayor precisión que las arquitecturas tradicionales.
¿Qué métodos de preprocesamiento de imágenes serán utilizados para mejorar la precisión del modelo de deep learning en la detección de retinopatía diabética?	Evaluar los métodos de preprocesamiento de imágenes que mejoren la precisión del modelo de deep learning en la detección de retinopatía diabética.	Los métodos de preprocesamiento de imágenes aplicados mejorarán la precisión del modelo de deep learning en la detección de la retinopatía diabética.
¿Qué métricas serán utilizadas para evaluar y comparar la efectividad de diferentes modelos de deep learning en la detección de la retinopatía diabética?	Definir y utilizar métricas para evaluar y comparar la efectividad de diferentes modelos de deep learning en la detección de la retinopatía diabética.	Las métricas definidas y utilizadas para evaluar los modelos de deep learning proporcionarán una comparación clara y efectiva de la precisión y efectividad de diferentes modelos en la detección de la retinopatía diabética.

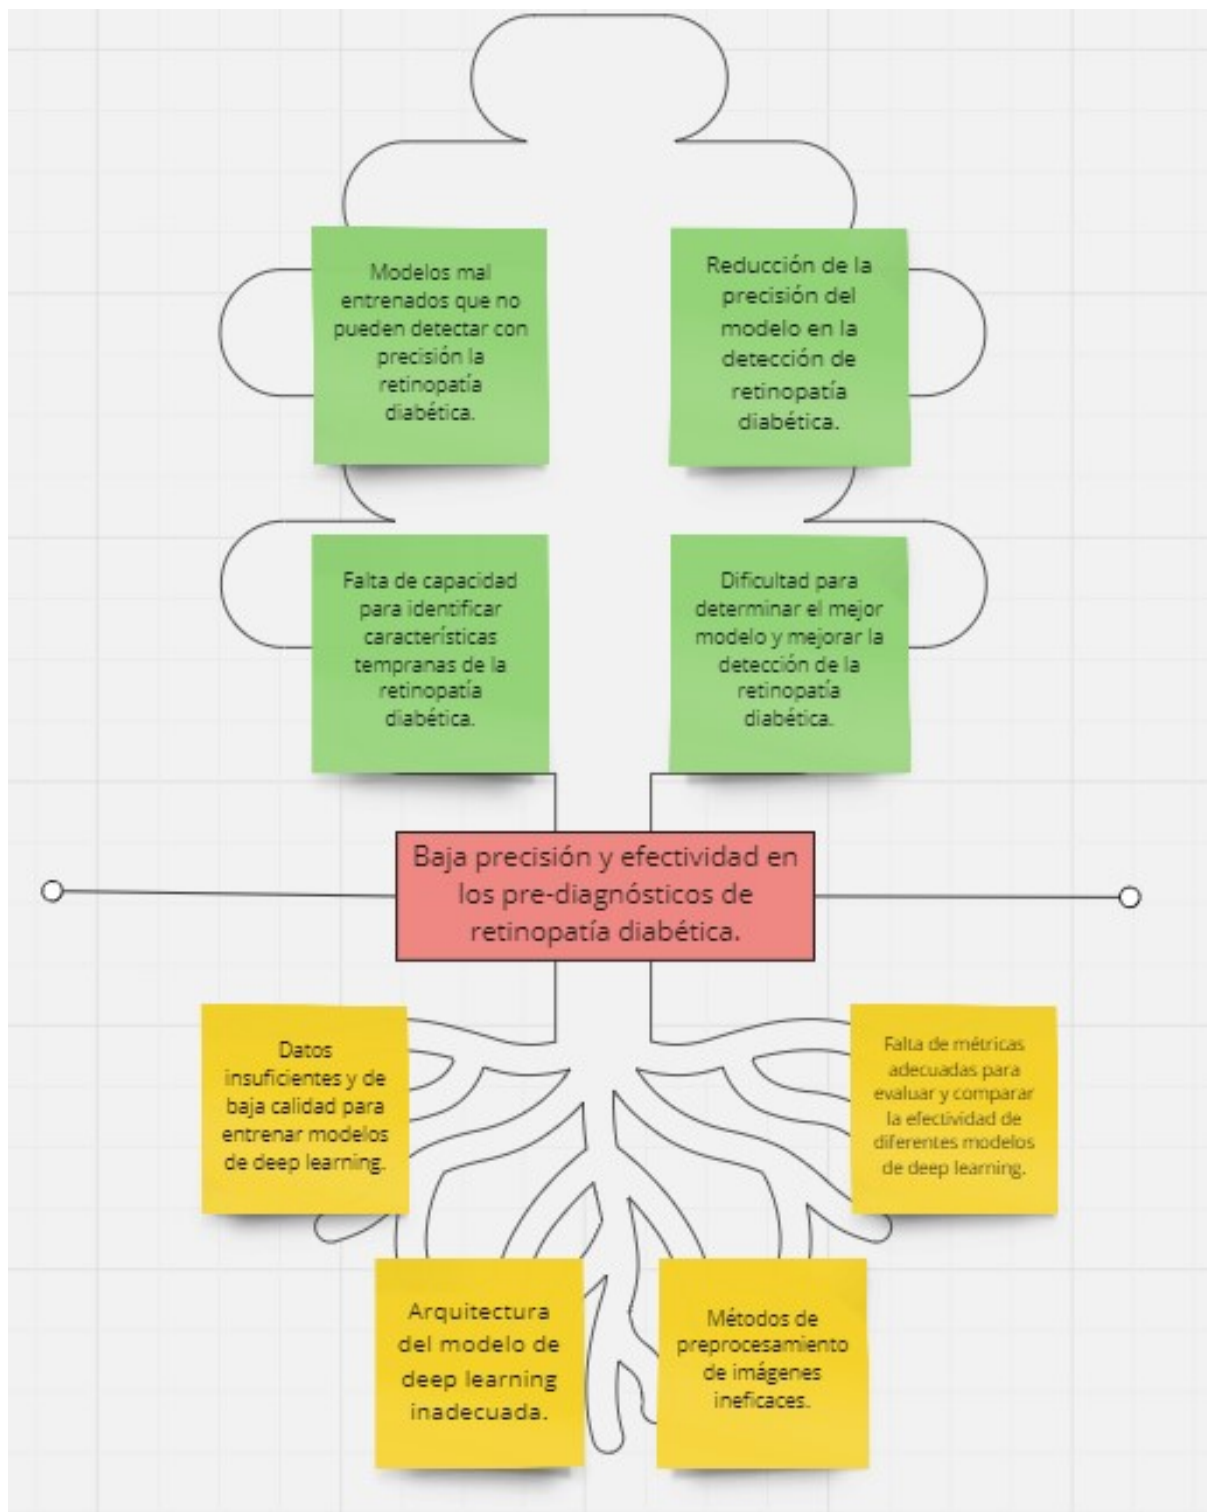
**Figura A.1:** Matriz de consistencia (Parte 1). Fuente: Elaboración propia

VARIABLES	INDICADORES	FÓRMULAS
<ul style="list-style-type: none"> <li>• VD: Resultados de pre-diagnósticos de retinopatía diabética</li> <li>• VI: Implementación de modelo de deep learning</li> </ul>	<ul style="list-style-type: none"> <li>• Precisión del modelo</li> <li>• Recall</li> <li>• F1 Score</li> </ul>	<ul style="list-style-type: none"> <li>• <math>\text{Precisión} = \frac{TP}{TP + FP}</math></li> <li>• <math>\text{Recall} = \frac{TP}{TP + FN}</math></li> <li>• <math>\text{F1 Score} = 2 \times \frac{\text{Precisión} \times \text{Recall}}{\text{Precisión} + \text{Recall}}</math></li> </ul>
<ul style="list-style-type: none"> <li>• VD: Precisión en la pre-detección de retinopatía diabética</li> <li>• VI: Datos de entrenamiento seleccionados</li> </ul>	<ul style="list-style-type: none"> <li>• Calidad de los datos</li> <li>• Cobertura de datos</li> </ul>	<ul style="list-style-type: none"> <li>• <math>\text{Calidad de los datos} = \frac{\text{Cantidad de datos precisos y actualizados}}{\text{Total de datos utilizados}} \times 100</math></li> <li>• <math>\text{Cobertura de datos} = \frac{\text{Cantidad de datos útiles}}{\text{Total de datos disponibles}} \times 100</math></li> </ul>
<ul style="list-style-type: none"> <li>• VD: Precisión en la identificación de características tempranas</li> <li>• VI: Arquitectura del modelo de deep learning</li> </ul>	<ul style="list-style-type: none"> <li>• Precisión del modelo</li> <li>• Capacidad de generalización</li> </ul>	<ul style="list-style-type: none"> <li>• <math>\text{Precisión} = \frac{TP}{TP + FP}</math></li> <li>• <math>\text{Capacidad de generalización} = \frac{\text{Número de características correctamente identificadas en nuevos datos}}{\text{Total de características identificadas}} \times 100</math></li> </ul>
<ul style="list-style-type: none"> <li>• VD: Precisión en la detección de retinopatía diabética</li> <li>• VI: Métodos de pre-procesamiento de imágenes</li> </ul>	<ul style="list-style-type: none"> <li>• Eficiencia del preprocesamiento</li> <li>• Tiempo de procesamiento</li> </ul>	<ul style="list-style-type: none"> <li>• <math>\text{Eficiencia del preprocesamiento} = \frac{\text{Número de imágenes preprocesadas correctamente}}{\text{Total de imágenes preprocesadas}} \times 100</math></li> <li>• <math>\text{Tiempo de procesamiento} = \text{Tiempo promedio por imagen}</math></li> </ul>
<ul style="list-style-type: none"> <li>• VD: Efectividad de diferentes modelos</li> <li>• VI: Métricas utilizadas para evaluación</li> </ul>	<ul style="list-style-type: none"> <li>• Comparación de efectividad</li> <li>• Rendimiento general</li> </ul>	<ul style="list-style-type: none"> <li>• <math>\text{Comparación de efectividad} = \frac{\text{Número de modelos evaluados con métricas establecidas}}{\text{Total de modelos evaluados}} \times 100</math></li> <li>• <math>\text{Rendimiento general} = \text{Evaluación del desempeño en múltiples métricas (precisión, recall, F1 Score)}</math></li> </ul>

**Figura A.2:** Matriz de consistencia (Parte 2). Fuente: Elaboración propia

## **Anexos B**

### **Anexo II: Árbol de Problemas**



**Figura B.1:** Árbol de Problemas. Fuente: Elaboración propia



## **Anexos C**

### **Anexo III: Resumen de Papers Investigados**

Tipo	N°	Título	Autor	Año	País	Fuente
Problema	1	Deep Convolutional Neural Networks for Detecting COVID-19 Using Medical Images: A Survey	Sharma, et al.	2020	India	<i>IEEE Access</i>
	2	Heart Disease Detection Using Machine Learning and Deep Learning Techniques	Jiang, et al.	2020	USA	<i>International Journal of Medical Informatics</i>
Propuesta	3	Monitoring and Recognition of Heart Health using Heartbeat Classification with Deep Learning and IoT	Arulkumar, et al.	2023	India	<i>Journal of Machine and Computing</i>
	4	Advances in Deep Learning: From Diagnosis to Treatment	Huang, et al.	2023	China	<i>BioScience Trends</i>
	5	A Study on Scope of Artificial Intelligence in Diagnostic Medicine	Santhosh Kumar, et al.	2023	India	<i>IEEE Access</i>
Otros	6	A Diabetic Retinopathy Detection using Customized Convolutional Neural Network	Mane, et al.	2023	India	<i>International Journal of Electrical and Electronics Research</i>
	7	Using Deep Learning Architectures for Detection and Classification of Diabetic Retinopathy	Mohanty, et al.	2023	India	<i>Sensors</i>
	8	Prevalencia de la retinopatía diabética y factores de riesgo asociados	Yáñez, et al.	2016	Peru	<i>Revista Médica Carrionica</i>

**Tabla C.1:** Cuadro Resumen de Papers Investigados. Fuente: Elaboración propia